

دانشگاه صنعتی شریف

ارزیابی شاخص‌های عملکرد موتوری در بیماران دوشن به کمک حسگرهای اینرسیایی

پایان‌نامه کارشناسی

استاد راهنما: دکتر سعید بهزادی‌پور



نام دانشجو: محمد رحمانی‌طلب

شماره دانشجویی: ۴۰۰۱۰۵۶۳۶

چکیده

بیماری دیستروفی عضلانی دوشن^۱ یکی از شایع‌ترین و شدیدترین اختلالات ژنتیکی عضلانی در کودکان است که با ضعف پیشرونده عضلات اسکلتی همراه بوده و به‌مرور زمان منجر به کاهش توانایی‌های حرکتی می‌شود. پایش دقیق و کمی عملکرد حرکتی بیماران مبتلا به این بیماری، نقش مهمی در ارزیابی روند پیشرفت بیماری، بررسی اثربخشی درمان‌ها و طراحی برنامه‌های توان‌بخشی ایفا می‌کند. در حال حاضر، یکی از ابزارهای رایج برای ارزیابی عملکرد حرکتی این بیماران، مقیاس NSAA^۲ است که بر اساس مشاهده بالینی و قضاوت درمانگر، نمره‌ای گسسته بین صفر تا دو به هر حرکت اختصاص می‌دهد. با وجود کاربرد گسترده این مقیاس، ماهیت کیفی و وابستگی آن به ارزیابی انسانی می‌تواند منجر به بروز خطاهای بین ارزیابان و کاهش دقت تکرارپذیری نتایج شود.

هدف این پژوهش، طراحی و توسعه یک سامانه مبتنی بر حسگرهای اینرسیایی به‌منظور ارزیابی کمی شاخص‌های عملکرد موتوری در بیماران مبتلا به دوشن و نزدیک‌سازی فرآیند نمره‌دهی به یک چارچوب داده‌محور است. در این راستا، مجموعه‌ای از حسگرهای اینرسیایی شامل شتاب‌سنج وژیروسکوپ بر روی بخش‌های کلیدی بدن نصب شده و داده‌های شتاب خطی و سرعت زاویه‌ای حین اجرای حرکات منتخب NSAA ثبت گردید. داده‌های خام جمع‌آوری شده پس از انتقال به محیط متلب MATLAB، تحت فرآیند پیش‌پردازش شامل حذف نویز، فیلترگذاری دیجیتال و در صورت نیاز نرمال‌سازی زمانی قرار گرفتند. در ادامه، با استخراج ویژگی‌های مناسب از حوزه زمان، مجموعه داده‌ای ساختاریافته برای تحلیل‌های بعدی آماده شد.

به‌منظور پیش‌بینی نمره هر حرکت، از الگوریتم‌های یادگیری ماشین استفاده گردید و نتایج حاصل با ارزیابی بالینی مقایسه شد. در فاز مقدماتی این پژوهش، بازدید میدانی و مشاهده وضعیت حرکتی حدود ۱۲ بیمار مبتلا به دیستروفی عضلانی دوشن با همکاری تیم بالینی انجام شد که درک عمیق‌تری از الگوهای حرکتی و محدودیت‌های عملی سیستم فراهم ساخت. نتایج نشان داد که رویکرد مبتنی بر حسگرهای اینرسیایی و تحلیل داده‌محور می‌تواند به‌عنوان ابزاری مکمل در کنار ارزیابی بالینی، به افزایش دقت، عینیت و قابلیت تکرارپذیری فرآیند نمره‌دهی کمک نماید.

این سامانه می‌تواند در آینده به‌عنوان زیرساختی برای پایش طولی بیماران، توسعه سامانه‌های ارزیابی از راه دور و بهبود تصمیم‌گیری‌های درمانی مورد استفاده قرار گیرد.

واژگان کلیدی: دیستروفی عضلانی دوشن، حسگر اینرسیایی، تحلیل حرکت، یادگیری ماشین، مقیاس NSAA، ارزیابی عملکرد حرکتی

^۱ Duchenne Muscular Dystrophy (DMD)

^۲ North Star Ambulatory Assessment

فهرست مطالب

۷	۱	مقدمه
۷	۱.۱	تاثیر دیستروفی عضلانی دوشن بر عملکرد حرکتی
۷	۲.۱	ارزیابی عملکرد حرکتی بیماران و چالش‌های موجود
۸	۳.۱	بیان مسئله
۸	۴.۱	اهداف پژوهش
۹	۵.۱	خروجی‌های مورد انتظار
۱۰	۲	مبانی نظری
۱۰	۱.۲	دیستروفی عضلانی دوشن
۱۰	۲.۲	مقیاس NSAA
۱۱	۳.۲	حسگرهای اینرسیایی
۱۱	۴.۲	پیش پردازش سیگنال
۱۲	۵.۲	استخراج ویژگی
۱۲	۶.۲	کاهش بعد داده‌ها
۱۳	۷.۲	یادگیری ماشین
۱۳	۸.۲	معیارهای ارزیابی مدل
۱۳	۹.۲	ماشین بردار پشتیبان
۱۴	۱۰.۲	الگوریتم نزدیک‌ترین همسایه
۱۴	۱۱.۲	جنگل تصادفی
۱۵	۳	طراحی و پیاده‌سازی سامانه پیشنهادی
۱۵	۱.۳	مقدمه
۱۵	۲.۳	روند انتخاب روش ارزیابی در پژوهش حاضر
۱۷	۳.۳	انتخاب مقیاس NSAA به عنوان معیار ارزیابی
۱۸	۴.۳	انتخاب حسگرهای اینرسیایی برای ثبت حرکات
۱۹	۵.۳	طراحی سامانه پیشنهادی
۲۰	۶.۳	پیاده‌سازی سامانه داده‌برداری
۲۰	۱.۶.۳	چیدمان سامانه اندازه‌گیری
۲۱	۲.۶.۳	دلایل انتخاب چیدمان حسگرها
۲۲	۳.۶.۳	نرم‌افزار تعبیه‌شده روی بردهای حسگر
۲۳	۴.۶.۳	نرم‌افزار توسعه‌یافته در محیط MATLAB
۲۴	۵.۶.۳	فرآیند انجام آزمون‌ها و ثبت داده‌ها
۲۵	۷.۳	پیش‌پردازش داده‌ها

۲۵	دریافت فایل‌های خام	۱.۷.۳
۲۶	فیلترگذاری سیگنال‌ها	۲.۷.۳
۲۶	جداسازی فعالیت‌ها	۳.۷.۳
۲۶	آماده‌سازی داده‌ها برای تحلیل	۴.۷.۳
۲۷	استخراج ویژگی‌ها	۸.۳
۲۷	ویژگی‌های استخراج‌شده	۱.۸.۳
۲۹	کاهش بعد ویژگی‌ها	۹.۳
۳۰	آموزش مدل‌های یادگیری ماشین	۱۰.۳
۳۰	تقسیم‌بندی تصادفی با تعداد نمونه ثابت	۱.۱۰.۳
۳۰	اعتبارسنجی متقاطع	۲.۱۰.۳
۳۰	مدل‌های مورد استفاده	۳.۱۰.۳
۳۱	Pipeline پردازش داده	۴.۱۰.۳
۳۱	معیارهای ارزیابی	۱۱.۳
۳۱	روند اجرای آزمایش‌ها	۱۲.۳
۳۲	مراحل اجرای Pipeline	۱.۱۲.۳
۳۳	ابزارهای نرم‌افزاری مورد استفاده	۱۳.۳

۴ نتایج و بحث ۳۴

۳۴	مقدمه	۱.۴
۳۴	بررسی داده‌های ثبت‌شده	۲.۴
۳۵	نتایج پیش‌پردازش داده‌ها	۳.۴
۳۶	نتایج استخراج ویژگی	۴.۴
۳۶	نتایج مدل‌های یادگیری ماشین	۵.۴
۳۹	تأثیر کاهش بعد با استفاده از PCA	۶.۴
۴۱	تحلیل ویژگی‌های مؤثر	۷.۴
۴۳	جمع‌بندی فصل	۸.۴

۵ جمع‌بندی ۴۴

۶ پیوست ۴۵

۷ مراجع ۴۶

فهرست تصاویر

۱	روند تصمیم‌گیری برای انتخاب روش ارزیابی عملکرد	۱۷
۲	معماری کلی سامانه پیشنهادی و جریان داده از مرحله ثبت اطلاعات تا پیش‌بینی نمره عملکردی	۲۰
۳	محل نصب پنچ حسگر اینرسیایی بر روی بدن آزمودنی	۲۱
۴	فلوچارت عملکرد نرم‌افزار اجرا شده روی هر واحد حسگر	۲۳
۵	رابط کاربری نرم‌افزار توسعه یافته در محیط MATLAB برای دریافت و ذخیره سازی همزمان داده‌های حسگرها	۲۴
۶	مراحل انجام فرآیند داده برداری در پژوهش حاضر	۲۵
۷	استخراج ویژگی	۲۹
۸	روند اجرای هر آزمایش در Pipeline طراحی شده	۳۲
۹	نمونه سیگنال های ثبت شده از حسگرها در فعالیت ایستادن	۳۴
۱۰	توزیع تعداد نمونه ها در کلاس های برچسب گذاری شده	۳۵
۱۱	نقشه همبستگی ۲۰ ویژگی با بیشترین واریانس	۳۶
۱۲	مقایسه معیارهای عملکرد مدل ها در دو حالت بدون PCA و با PCA95	۳۷
۱۳	ماتریس درهم ریختگی نرمال شده مدل ها در حالت no pca	۳۷
۱۴	ماتریس درهم ریختگی نرمال شده مدل ها در حالت pca95	۳۸
۱۵	رتبه بندی مدل ها بر اساس F1 در حالت بدون PCA	۳۸
۱۶	درصد واریانس توضیح داده شده و تجمعی مولفه های اصلی	۳۹
۱۷	پراکندگی نمونه ها در فضای PC1 و PC2	۴۰
۱۸	تغییر F1 هر مدل پس از اعمال PCA95	۴۰
۱۹	۲۰ ویژگی برتر بر اساس اهمیت در مدل Random Forest	۴۱
۲۰	مقایسه Recall هر کلاس بین مدل ها no pca	۴۲
۲۱	مقایسه Recall هر کلاس بین مدل ها pca95	۴۲
۲۲	میانگین نرمال شده ویژگی های برتر برای هر کلاس	۴۳

فهرست جداول

۲۱	 مشخصات سامانه داده‌برداری	۱
۲۸	 ویژگی‌های استخراج‌شده از هر سیگنال	۲
۳۹	 مقایسه عملکرد مدل‌های مختلف	۳

تقدیر و تشکر

در ابتدا لازم می‌دانم از استاد راهنمای محترم، جناب آقای دکتر سعید بهزادی پور، بابت حمایت علمی، راهنمایی‌های دقیق و پیگیری مستمر در تمامی مراحل این پروژه صمیمانه قدردانی کنم. رهنمودهای ایشان نقش تعیین‌کننده‌ای در شکل‌گیری مسیر پژوهش، انتخاب رویکردهای اجرایی و ارتقای کیفیت نتایج داشته است. همچنین از سرکار خانم دکتر مرضیه بابایی و سرکار خانم دکتر زهرا رزاقی بابت همراهی ارزشمند، ارائه دیدگاه‌های بالینی و کمک در درک بهتر شرایط بیماران و ملاحظات ارزیابی عملکرد حرکتی، نهایت تشکر را دارم. بازدیدهای میدانی و مشاهده وضعیت حدود ۱۲ بیمار مبتلا به Duchenne Muscular Dystrophy (DMD) در مراحل اولیه، در شناخت مسئله و طراحی چارچوب ارزیابی نقش مهمی ایفا کرد. در پایان، از خانواده و دوستانم که با صبوری و دلگرمی، زمینه تمرکز و پیشبرد این مسیر را فراهم کردند، سپاسگزارم.

۱ مقدمه

۱.۱ تاثیر دیستروفی عضلانی دوشن بر عملکرد حرکتی

اگرچه در سال‌های اخیر پیشرفت‌های قابل توجهی در زمینه درمان‌های دارویی، ژن‌درمانی و مراقبت‌های حمایتی صورت گرفته است، اما هنوز درمان قطعی برای این بیماری وجود ندارد. به همین دلیل، پایش مستمر وضعیت عملکردی بیماران و ارزیابی روند پیشرفت بیماری از اهمیت بالایی برخوردار است. نتایج این ارزیابی‌ها علاوه بر کمک به انتخاب روش درمان، در بررسی اثربخشی مداخلات درمانی، برنامه‌ریزی جلسات توان‌بخشی و انجام مطالعات بالینی نیز نقش اساسی ایفا می‌کنند [۱].

توسعه سامانه‌هایی که بتوانند اطلاعات حرکتی بیماران را به صورت کمی ثبت کرده و با حداقل وابستگی به نظر ارزیاب تحلیل کنند، در سال‌های اخیر مورد توجه بسیاری از پژوهشگران قرار گرفته است. بهره‌گیری از حسگرهای پوشیدنی و روش‌های تحلیل داده این امکان را فراهم می‌کند که بخشی از فرآیند ارزیابی عملکرد بیماران به صورت خودکار انجام شود. پژوهش حاضر نیز با همین رویکرد طراحی و اجرا شده است.

۲.۱ ارزیابی عملکرد حرکتی بیماران و چالش‌های موجود

از آنجا که دیستروفی عضلانی دوشن یک بیماری پیشرونده است، ارزیابی مستمر وضعیت عملکرد حرکتی بیماران نقش مهمی در مدیریت روند درمان و توان‌بخشی آن‌ها ایفا می‌کند. پزشکان و درمانگران با بررسی تغییرات عملکرد حرکتی در طول زمان، می‌توانند سرعت پیشرفت بیماری را ارزیابی کرده، اثربخشی مداخلات درمانی را بررسی کنند و در صورت نیاز برنامه درمانی بیمار را اصلاح نمایند. به همین دلیل، ارزیابی عملکرد حرکتی به یکی از بخش‌های جدایی‌ناپذیر مراقبت از بیماران مبتلا به دیستروفی عضلانی دوشن تبدیل شده است [۱].

بر خلاف بسیاری از بیماری‌ها که وضعیت بیمار را می‌توان با یک آزمایش آزمایشگاهی یا تصویربرداری مشخص ارزیابی کرد، در دیستروفی عضلانی دوشن بخش قابل توجهی از اطلاعات مورد نیاز پزشک از نحوه انجام فعالیت‌های روزمره توسط بیمار به دست می‌آید. فعالیت‌هایی نظیر راه رفتن، برخاستن از زمین، بالا رفتن از پله‌ها، حفظ تعادل و سایر حرکات عملکردی، اطلاعات ارزشمندی درباره وضعیت عضلات و توانایی حرکتی بیمار در اختیار پزشک قرار می‌دهند.

در حال حاضر، بخش عمده این ارزیابی‌ها از طریق مشاهده مستقیم بیمار توسط پزشک یا درمانگر انجام می‌شود. اگرچه این روش‌ها طی سال‌ها اعتبار بالینی خود را اثبات کرده‌اند، اما ماهیت مشاهده‌ای آن‌ها سبب می‌شود نتایج تا حدی به تجربه ارزیاب، شرایط انجام آزمون و حتی وضعیت جسمی و روحی بیمار در زمان ارزیابی وابسته باشد. علاوه بر این، انجام این ارزیابی‌ها مستلزم حضور بیمار در مرکز درمانی بوده و معمولاً در فواصل زمانی نسبتاً طولانی تکرار می‌شوند؛ در نتیجه امکان پایش مداوم روند پیشرفت بیماری محدود خواهد بود.

در سال‌های اخیر، توسعه روش‌های کمی برای تحلیل حرکت انسان توجه بسیاری از پژوهشگران را به خود جلب کرده است. هدف این روش‌ها، استخراج اطلاعات قابل اندازه‌گیری از حرکات بدن و کاهش وابستگی ارزیابی به قضاوت ذهنی افراد است. استفاده از تجهیزات اندازه‌گیری حرکت و روش‌های پردازش داده این امکان را فراهم می‌کند که ویژگی‌های سینماتیکی حرکت به صورت عددی استخراج شده و تغییرات عملکرد بیمار در طول زمان با دقت بیشتری بررسی شود [۲].

با توجه به این نیاز، پژوهش‌های متعددی در سال‌های اخیر به دنبال توسعه سامانه‌هایی برای ثبت، تحلیل و ارزیابی خودکار حرکات بیماران بوده‌اند. اگرچه در بسیاری از مطالعات از سامانه‌های اپتیکی تحلیل حرکت نیز استفاده شده است، اما این سامانه‌ها معمولاً به فضای آزمایشگاهی، دوربین‌های متعدد و فرآیند کالیبراسیون پیچیده نیاز دارند. در مقابل، حسگرهای اینرسیایی^۲ ضمن حفظ دقت مناسب برای بسیاری از کاربردهای بالینی، هزینه کمتر، قابلیت حمل و سهولت استفاده بیشتری دارند. این ویژگی‌ها سبب شده است که استفاده از حسگرهای اینرسیایی به یکی از رویکردهای رایج در تحلیل حرکت بیماران تبدیل شود. انتخاب ابزار اندازه‌گیری مناسب و معیار بالینی قابل اعتماد، دو مؤلفه اصلی در طراحی چنین سامانه‌هایی به شمار می‌روند. در بخش‌های بعدی، ابتدا روش‌های متداول اندازه‌گیری حرکت معرفی شده و سپس معیار ارزیابی انتخاب‌شده در این پژوهش ارائه خواهد شد.

۳.۱ بیان مسئله

ارزیابی عملکرد حرکتی یکی از مهم‌ترین ابزارهای پایش روند پیشرفت بیماری در بیماران مبتلا به دیستروفی عضلانی دوشن است. نتایج این ارزیابی‌ها در تصمیم‌گیری‌های درمانی، برنامه‌ریزی جلسات توان‌بخشی، بررسی اثربخشی داروها و همچنین انجام مطالعات بالینی مورد استفاده قرار می‌گیرد. از این رو، دقت و تکرارپذیری فرآیند ارزیابی اهمیت بالایی دارد.

در روش‌های رایج، بخش عمده‌ای از ارزیابی عملکرد بیماران توسط پزشک یا درمانگر و بر اساس مشاهده مستقیم نحوه انجام فعالیت‌های مختلف صورت می‌گیرد. اگرچه این روش‌ها طی سال‌ها اعتبار بالینی خود را اثبات کرده‌اند، اما بخشی از فرآیند نمره‌دهی به تجربه ارزیاب و برداشت وی از کیفیت اجرای حرکت وابسته است. علاوه بر این، انجام ارزیابی مستلزم حضور بیمار در مرکز درمانی بوده و امکان ثبت مداوم تغییرات عملکردی بیمار در فواصل زمانی کوتاه وجود ندارد.

از سوی دیگر، پیشرفت فناوری حسگرهای پوشیدنی و روش‌های تحلیل داده، امکان اندازه‌گیری کمی بسیاری از ویژگی‌های حرکتی را فراهم کرده است. ثبت شتاب خطی و سرعت زاویه‌ای اندام‌های مختلف بدن می‌تواند اطلاعات ارزشمندی درباره نحوه اجرای حرکات در اختیار قرار دهد. با این حال، تبدیل این داده‌های خام به شاخص‌هایی که بتوانند وضعیت عملکردی بیمار را توصیف کنند، همچنان یکی از چالش‌های اصلی این حوزه محسوب می‌شود.

بر همین اساس، مسئله اصلی این پژوهش طراحی و توسعه سامانه‌ای مبتنی بر حسگرهای اینرسیایی است که بتواند داده‌های حرکتی بیماران دیستروفی عضلانی دوشن را ثبت کرده، پس از پردازش مناسب، ویژگی‌های مؤثر را استخراج نموده و با استفاده از روش‌های یادگیری ماشین، ارتباط میان داده‌های حرکتی و ارزیابی بالینی بیماران را مدل‌سازی کند.

۴.۱ اهداف پژوهش

هدف این پژوهش توسعه یک چارچوب یکپارچه برای ثبت داده‌های حرکتی بیماران مبتلا به دیستروفی عضلانی دوشن، استخراج ویژگی‌های مناسب از سیگنال‌های ثبت‌شده و پیش‌بینی نمرات عملکردی با استفاده از الگوریتم‌های

^۲ Inertial Measurement Unit (IMU)

یادگیری ماشین است. انتظار می‌رود نتایج این پژوهش بتواند گامی در جهت ارائه روشی کم‌هزینه، کمی و قابل تکرار برای کمک به ارزیابی عملکرد حرکتی بیماران باشد.

اهداف فرعی پژوهش عبارت‌اند از:

- مطالعه روش‌های متداول ارزیابی عملکرد حرکتی بیماران مبتلا به دیستروفی عضلانی دوشن؛
- طراحی سامانه اندازه‌گیری مبتنی بر حسگرهای اینرسیایی و انتخاب محل مناسب نصب حسگرها؛
- توسعه نرم‌افزار دریافت، ذخیره‌سازی و مدیریت داده‌های حسگرها؛
- پیش‌پردازش داده‌های ثبت‌شده و استخراج ویژگی‌های مناسب از سیگنال‌های حرکتی؛
- بررسی تأثیر روش‌های مختلف کاهش بعد بر داده‌های استخراج‌شده؛
- آموزش و ارزیابی مدل‌های مختلف یادگیری ماشین برای پیش‌بینی نمرات عملکردی؛
- مقایسه عملکرد مدل‌های مختلف و انتخاب مناسب‌ترین مدل برای مسئله مورد مطالعه.

۵.۱ خروجی‌های مورد انتظار

انتظار می‌رود سامانه توسعه‌یافته بتواند به‌عنوان ابزاری مکمل در کنار ارزیابی‌های بالینی مورد استفاده قرار گیرد و با ارائه شاخص‌های کمی، به افزایش عینیت، دقت و تکرارپذیری فرآیند نمره‌دهی کمک نماید. همچنین این چارچوب می‌تواند زمینه‌ای برای توسعه سامانه‌های پایش طولی بیماران و کاربردهای ارزیابی از راه دور در آینده فراهم سازد.

۲ مبانی نظری

۱.۲ دیستروفی عضلانی دوشن

دیستروفی عضلانی دوشن^۴ یکی از شایع‌ترین بیماری‌های ژنتیکی عصبی-عضلانی^۵ در کودکان است که به‌صورت وابسته به کروموزوم X به ارث می‌رسد و عمدتاً پسران را درگیر می‌کند [۳]. این بیماری در اثر جهش در ژن دیستروفین^۶ ایجاد می‌شود و در نتیجه آن، پروتئین دیستروفین که نقش مهمی در حفظ پایداری ساختاری سلول‌های عضلانی دارد، به مقدار کافی تولید نمی‌شود [۴]. نبود این پروتئین موجب آسیب تدریجی فیبرهای عضلانی و در نهایت جایگزینی آن‌ها با بافت چربی و همبند می‌شود. علاوه بر این دیستروفین نقش مهمی در پایداری مکانیکی غشای سلول‌های عضلانی دارد و اختلال در آن موجب آسیب‌پذیری فیبرهای عضلانی در برابر تنش‌های مکانیکی ناشی از انقباض می‌گردد.

از منظر بالینی، نشانه‌های بیماری غالباً در سال‌های ابتدایی کودکی ظاهر می‌شوند و می‌توانند شامل تأخیر در مهارت‌های حرکتی، دشواری در دویدن و بالا رفتن از پله‌ها، الگوی راه رفتن غیرطبیعی و زمین خوردن‌های مکرر باشند [۱]. یکی از نشانه‌های شناخته‌شده در بسیاری از بیماران، Gowers' sign^۷ است که به ضعف عضلات کمر بند لگنی نسبت داده می‌شود.

با پیشرفت بیماری، افت عملکرد حرکتی به‌صورت تدریجی رخ می‌دهد و در بسیاری از بیماران در سنین نوجوانی از دست رفتن توانایی راه رفتن مستقل مشاهده می‌شود. همچنین در مراحل پیشرفته‌تر، درگیری سیستم تنفسی و قلبی می‌تواند بر کیفیت زندگی و پیامدهای بالینی اثرگذار باشد [۵].

۲.۲ مقیاس NSAA

مقیاس NSAA^۸ یکی از ابزارهای استاندارد ارزیابی عملکرد حرکتی در بیماران سرپایی مبتلا به دیستروفی عضلانی دوشن است که به‌طور گسترده در کارآزمایی‌های بالینی و مطالعات پایش طولی مورد استفاده قرار می‌گیرد [۶]. این مقیاس به‌طور اختصاصی برای بیماران دیستروفی عضلانی دوشن طراحی شده و هدف آن اندازه‌گیری توانایی انجام فعالیت‌های عملکردی روزمره مرتبط با راه رفتن و تعادل است.

NSAA شامل ۱۷ فعالیت عملکردی است که طیفی از حرکات پایه تا فعالیت‌های دینامیک‌تر مانند پریدن و دویدن را دربرمی‌گیرد. هر فعالیت بر اساس یک مقیاس ترتیبی سه‌سطحی امتیازدهی می‌شود:

□ نمره ۲: اجرای طبیعی و مستقل حرکت بدون استفاده از الگوهای جبرانی؛

□ نمره ۱: اجرای مستقل همراه با جبران حرکتی یا تغییر در الگوی طبیعی حرکت؛

□ نمره ۰: ناتوانی در انجام مستقل فعالیت.

^۴Duchenne Muscular Dystrophy (DMD)

^۵Neuromuscular

^۶Dystrophin

^۷الگوی جبرانی برخاستن از زمین

^۸North Star Ambulatory Assessment

حداکثر امتیاز قابل کسب در این مقیاس ۳۴ است که نشان‌دهنده عملکرد کامل حرکتی است. از آنجا که این مقیاس ماهیتی ترتیبی دارد، فاصله بین نمرات لزوماً بیانگر اختلاف عددی خطی در کیفیت حرکت نیست، بلکه نشان‌دهنده طبقه‌بندی سطوح عملکردی است.

۳.۲ حسگرهای اینرسیایی

حسگرهای اینرسیایی^۹ ابزارهایی پوشیدنی برای اندازه‌گیری پارامترهای سینماتیکی حرکت هستند. این واحدها عموماً شامل شتاب‌سنج^{۱۰} وژیروسکوپ^{۱۱} سه‌محوره بوده و امکان ثبت شتاب خطی و سرعت زاویه‌ای را در راستای سه محور مختصاتی فراهم می‌کنند [۷].

شتاب‌سنج میزان شتاب خطی وارد بر حسگر را اندازه‌گیری می‌کند که شامل مؤلفه ناشی از حرکت و مؤلفه گرانشی است. بنابراین، در تحلیل حرکت لازم است اثر شتاب گرانشی از داده‌ها تفکیک یا جبران شود تا مؤلفه‌های دینامیکی حرکت استخراج گردند [۸]. ژيروسکوپ نیز سرعت زاویه‌ای حول محورهای مختصاتی را ثبت می‌کند و امکان تحلیل چرخش اندام‌ها و تغییرات وضعیت زاویه‌ای را فراهم می‌سازد.

داده‌های حاصل از حسگر اینرسیایی ممکن است تحت تأثیر نویز اندازه‌گیری، خطای کالیبراسیون و رانش انتگرالی^{۱۲} قرار گیرند. این موضوع به‌ویژه در کاربردهایی که نیاز به تخمین وضعیت زاویه‌ای دقیق دارند، اهمیت بیشتری پیدا می‌کند. از این‌رو، استفاده از روش‌های مناسب پیش‌پردازش و فیلترگذاری برای افزایش دقت و پایداری داده‌ها ضروری است.

۴.۲ پیش‌پردازش سیگنال

داده‌های خام حاصل از حسگرهای اینرسیایی معمولاً شامل نویز اندازه‌گیری، مؤلفه‌های ناخواسته و تغییرات غیرمرتبط با فعالیت هدف هستند. بنابراین پیش از انجام هرگونه تحلیل کمی، لازم است فرآیند پیش‌پردازش سیگنال انجام شود. فیلترگذاری مناسب برای حذف نویز و افزایش نسبت سیگنال به نویز یکی از گام‌های مهم در تحلیل داده‌ها است [۲].

یکی از روش‌های رایج در تحلیل حرکت، استفاده از فیلترهای دیجیتال پایین‌گذر مانند فیلتر Butterworth است. این فیلتر به دلیل پاسخ فرکانسی یکنواخت در باند عبور و عدم ایجاد نوسانات شدید در سیگنال، در کاربردهای بیومکانیکی متداول است [۲]. انتخاب فرکانس قطع مناسب باید با توجه به ماهیت حرکت و نرخ نمونه‌برداری انجام شود.

قطعه‌بندی زمانی^{۱۳} نیز نقش مهمی در تحلیل فعالیت‌های حرکتی دارد. در این فرآیند، سیگنال پیوسته به بازه‌هایی متناظر با هر فعالیت مشخص تقسیم می‌شود تا امکان استخراج ویژگی‌های مرتبط با هر حرکت فراهم گردد. همچنین نرمال‌سازی^{۱۴} زمانی به مقایسه بین آزمودنی‌ها یا اجرای‌های مختلف یک فعالیت کمک می‌کند.

^۹ Inertial Measurement Unit (IMU)

^{۱۰} Accelerometer

^{۱۱} Gyroscope

^{۱۲} افزایش تدریجی خطا در تخمین زاویه که ناشی از انتگرال‌گیری طولانی‌مدت از سرعت زاویه‌ای است.

^{۱۳} Segmentation

^{۱۴} Data Normalization

۵.۲ استخراج ویژگی

پس از انجام مراحل پیش پردازش، داده‌های حاصل از حسگرهای اینرسیایی همچنان به صورت سیگنال‌های خام و دنباله‌های زمانی در اختیار هستند. اگرچه این سیگنال‌ها اطلاعات کاملی از نحوه انجام حرکت را در خود دارند، اما استفاده مستقیم از آن‌ها در بسیاری از الگوریتم‌های یادگیری ماشین به دلیل ابعاد بالا، وجود هم‌بستگی میان نمونه‌ها و حساسیت به نویز، معمولاً منجر به افزایش هزینه محاسباتی و کاهش قابلیت تعمیم مدل می‌شود. از این رو، در بسیاری از مطالعات تحلیل حرکت، پیش از آموزش مدل، مجموعه‌ای از ویژگی‌های توصیف‌کننده از سیگنال استخراج می‌شود [۹].

استخراج ویژگی^{۱۵} فرآیندی است که طی آن، اطلاعات مهم موجود در سیگنال خام به مجموعه‌ای از شاخص‌های عددی با ابعاد کمتر تبدیل می‌شود. هدف از این مرحله، حفظ اطلاعات مؤثر بر رفتار سیگنال و حذف اطلاعات غیرضروری یا تکراری است. ویژگی‌های استخراج‌شده می‌توانند نمایانگر خصوصیات آماری، زمانی یا فرکانسی سیگنال بوده و به الگوریتم یادگیری ماشین در شناسایی الگوهای موجود در داده کمک کنند. به طور کلی، ویژگی‌های مورد استفاده در تحلیل سیگنال‌های حرکتی را می‌توان به دو گروه اصلی تقسیم کرد: ویژگی‌های حوزه زمان^{۱۶} و ویژگی‌های حوزه فرکانس^{۱۷}. ویژگی‌های حوزه زمان مستقیماً از مقادیر نمونه‌های سیگنال محاسبه می‌شوند و شاخص‌هایی مانند میانگین، انحراف معیار، واریانس، دامنه تغییرات، انرژی و چولگی را شامل می‌شوند. این ویژگی‌ها علاوه بر سادگی محاسبه، اطلاعات مناسبی از شدت حرکت، میزان تغییرات و رفتار کلی سیگنال ارائه می‌دهند.

در مقابل، ویژگی‌های حوزه فرکانس با تبدیل سیگنال به حوزه فرکانسی، معمولاً با استفاده از تبدیل فوریه^{۱۸} استخراج می‌شوند. این ویژگی‌ها اطلاعاتی درباره توزیع انرژی سیگنال در فرکانس‌های مختلف، فرکانس غالب و سایر مشخصات طیفی ارائه می‌کنند و در برخی کاربردهای تحلیل حرکت و شناسایی فعالیت‌های انسانی مورد استفاده قرار می‌گیرند [۹].

۶.۲ کاهش بعد داده‌ها

در بسیاری از مسائل تحلیل داده، تعداد ویژگی‌های استخراج‌شده از سیگنال‌ها بسیار زیاد است. افزایش تعداد ویژگی‌ها علاوه بر افزایش زمان آموزش مدل‌ها، می‌تواند موجب افزایش پیچیدگی مدل و کاهش قابلیت تعمیم آن شود. به همین دلیل، از روش‌های کاهش بعد برای نمایش داده‌ها در فضایی با ابعاد کمتر استفاده می‌شود. یکی از متداول‌ترین روش‌های کاهش بعد، تحلیل مؤلفه‌های اصلی^{۱۹} است. این روش با ایجاد ترکیب‌های خطی جدید از ویژگی‌های اولیه، داده‌ها را به مجموعه‌ای از مؤلفه‌های مستقل تبدیل می‌کند که بیشترین میزان واریانس موجود در داده را حفظ می‌کنند [۱۰].

^{۱۵} Feature Extraction

^{۱۶} Time-domain Features

^{۱۷} Frequency-domain Features

^{۱۸} Fast Fourier Transform (FFT)

^{۱۹} Principal Component Analysis (PCA)

۷.۲ یادگیری ماشین

یادگیری ماشین^{۲۰} مجموعه‌ای از روش‌های محاسباتی است که به سیستم‌ها امکان می‌دهد الگوهای موجود در داده‌ها را یاد گرفته و بر اساس آن پیش‌بینی یا طبقه‌بندی انجام دهند [۱۱]. در تحلیل حرکت انسان، این روش‌ها به‌طور گسترده برای شناسایی فعالیت‌ها، طبقه‌بندی الگوهای حرکتی و پیش‌بینی شاخص‌های عملکردی به کار گرفته شده‌اند.

در چارچوب یادگیری نظارت‌شده^{۲۱} مدل با استفاده از داده‌های برچسب‌دار^{۲۲} آموزش می‌بیند؛ به این معنا که برای هر نمونه داده، خروجی صحیح (مانند نوع فعالیت یا نمره عملکردی) مشخص است. پس از آموزش، مدل می‌تواند برای داده‌های جدید، خروجی متناظر را پیش‌بینی کند. روش‌هایی مانند ماشین بردار پشتیبان^{۲۳} درخت تصمیم^{۲۴} و شبکه‌های عصبی مصنوعی^{۲۵} از جمله الگوریتم‌هایی هستند که در مطالعات تحلیل فعالیت انسانی کاربرد گسترده‌ای داشته‌اند [۱۲].

در زمینه تحلیل داده‌های حسگرهای پوشیدنی، یادگیری ماشین به‌عنوان ابزاری برای استخراج الگوهای پیچیده و غیرخطی از داده‌های چندبعدی شناخته می‌شود. ویژگی‌های استخراج‌شده از سیگنال‌های شتاب و سرعت زاویه‌ای می‌توانند به‌عنوان ورودی مدل قرار گرفته و رابطه آن‌ها با شاخص‌های عملکردی مدل‌سازی شود.

۸.۲ معیارهای ارزیابی مدل

برای ارزیابی عملکرد الگوریتم‌های یادگیری ماشین از معیارهای متداول طبقه‌بندی استفاده می‌شود. دقت^{۲۶} نسبت نمونه‌های طبقه‌بندی‌شده صحیح به کل نمونه‌ها را نشان می‌دهد. با این حال، در مسائل دارای عدم توازن داده، استفاده از معیارهایی مانند Precision، Recall و F1-score اطلاعات دقیق‌تری از عملکرد مدل ارائه می‌دهد. همچنین ماتریس درهم‌ریختگی^{۲۷} ابزاری مناسب برای تحلیل نحوه طبقه‌بندی نمونه‌ها و شناسایی خطاهای مدل محسوب می‌شود. در این پژوهش از تمامی این معیارها برای مقایسه عملکرد الگوریتم‌های مختلف استفاده شده است.

۹.۲ ماشین بردار پشتیبان

ماشین بردار پشتیبان^{۲۸} یکی از پرکاربردترین الگوریتم‌های یادگیری نظارت‌شده برای مسائل طبقه‌بندی است. ایده اصلی این روش، یافتن ابرصفحه‌ای است که بتواند کلاس‌های مختلف را با بیشترین حاشیه ممکن از یکدیگر جدا کند [۱۳].

Machine Learning^{۲۰}

Supervised Learning^{۲۱}

Labeled Data^{۲۲}

Support Vector Machine^{۲۳}

Decision Tree^{۲۴}

Artificial Neural Networks (ANN)^{۲۵}

Accuracy^{۲۶}

Confusion Matrix^{۲۷}

Support Vector Machine (SVM)^{۲۸}

در مواردی که داده‌ها به صورت خطی قابل جداسازی نباشند، با استفاده از توابع هسته^{۲۹} می‌توان داده‌ها را به فضای با ابعاد بالاتر نگاشت و جداسازی مناسب‌تری انجام داد. از متداول‌ترین هسته‌ها می‌توان به هسته خطی، چندجمله‌ای و تابع پایه شعاعی^{۳۰} اشاره کرد. SVM توانایی بالا در مدل‌سازی مرزهای تصمیم پیچیده و عملکرد مناسب در مجموعه داده‌های با ابعاد زیاد دارد.

۱۰.۲ الگوریتم نزدیک‌ترین همسایه

الگوریتم نزدیک‌ترین همسایه^{۳۱} یکی از ساده‌ترین روش‌های طبقه‌بندی مبتنی بر نمونه است. در این روش، نمونه جدید بر اساس نزدیک‌ترین نمونه‌های موجود در مجموعه آموزش طبقه‌بندی می‌شود [۱۴]. ملاک نزدیکی معمولاً فاصله اقلیدسی است و پارامتر اصلی این الگوریتم، تعداد همسایه‌های مورد استفاده (k) است. انتخاب مقدار مناسب برای این پارامتر تأثیر قابل توجهی بر عملکرد مدل دارد؛ به گونه‌ای که مقادیر کوچک ممکن است موجب حساسیت زیاد به نویز شوند و مقادیر بزرگ احتمال هموار شدن بیش از حد مرز تصمیم را افزایش دهند.

۱۱.۲ جنگل تصادفی

جنگل تصادفی^{۳۲} یکی از روش‌های یادگیری مبتنی بر اجتماع مدل‌ها^{۳۳} است که از مجموعه‌ای از درخت‌های تصمیم برای انجام طبقه‌بندی استفاده می‌کند [۱۵]. در این روش، هر درخت تصمیم با استفاده از زیرمجموعه‌ای تصادفی از داده‌های آموزشی و همچنین زیرمجموعه‌ای از ویژگی‌ها ساخته می‌شود. در مرحله پیش‌بینی، خروجی نهایی از طریق رأی‌گیری میان تمامی درخت‌ها تعیین می‌شود.

استفاده از چندین درخت تصمیم موجب کاهش بیش‌برازش، افزایش پایداری مدل و بهبود دقت پیش‌بینی می‌شود. به همین دلیل، Random Forest در بسیاری از مسائل تحلیل داده‌های زیستی و داده‌های حاصل از حسگرهای پوشیدنی عملکرد مناسبی از خود نشان داده است.

^{۲۹} Kernel Function

^{۳۰} Radial Basis Function (RBF)

^{۳۱} K-Nearest Neighbors (KNN)

^{۳۲} Random Forest

^{۳۳} Ensemble Learning

۳ طراحی و پیاده‌سازی سامانه پیشنهادی

۱.۳ مقدمه

پس از تعیین چارچوب کلی پژوهش و انتخاب معیار مرجع برای ارزیابی عملکرد بیماران، گام بعدی طراحی سامانه‌ای بود که بتواند تمامی مراحل مورد نیاز از ثبت داده‌های حرکتی تا پیش‌بینی نمرات عملکردی را پوشش دهد. از آنجا که هدف این پژوهش صرفاً بررسی یک الگوریتم یادگیری ماشین نبود، توسعه سامانه به گونه‌ای انجام شد که تمامی مراحل اندازه‌گیری، مدیریت داده‌ها، پردازش سیگنال و تحلیل اطلاعات به صورت یک فرآیند منسجم در کنار یکدیگر قرار گیرند.

فرآیند توسعه سامانه به صورت مرحله‌ای انجام شد. در ابتدا زیرساخت سخت‌افزاری برای ثبت داده‌های حرکتی طراحی گردید. پس از آن، نرم‌افزار لازم برای دریافت، نمایش و ذخیره‌سازی داده‌های حسگرها توسعه داده شد تا امکان ایجاد یک بانک اطلاعاتی منظم از آزمون‌های انجام‌شده فراهم شود. در ادامه، داده‌های ثبت‌شده وارد مرحله پیش‌پردازش شدند و پس از استخراج ویژگی‌های مناسب، مدل‌های مختلف یادگیری ماشین برای پیش‌بینی نمرات عملکردی آموزش داده شدند.

با توجه به ماهیت میان‌رشته‌ای پروژه، توسعه سامانه را می‌توان در سه بخش اصلی خلاصه کرد:

□ طراحی و پیاده‌سازی سامانه اندازه‌گیری مبتنی بر حسگرهای اینرسیایی؛

□ توسعه ابزارهای نرم‌افزاری برای دریافت، مدیریت و پردازش داده‌ها؛

□ طراحی و ارزیابی مدل‌های یادگیری ماشین برای پیش‌بینی نمرات عملکردی.

در ادامه این فصل، ابتدا معماری کلی سامانه معرفی می‌شود و سپس جزئیات هر یک از بخش‌های سخت‌افزاری و نرم‌افزاری، فرآیند ثبت داده‌ها، مراحل پردازش اطلاعات و طراحی مدل‌های یادگیری ماشین به تفصیل تشریح خواهد شد.

۲.۳ روند انتخاب روش ارزیابی در پژوهش حاضر

پس از تعریف کلی مسئله پژوهش، نخستین گام بررسی روش‌های متداول ارزیابی عملکرد حرکتی بیماران مبتلا به دیستروفی عضلانی دوشن بود. هدف از این مرحله، انتخاب روشی بود که علاوه بر اعتبار بالینی، امکان اندازه‌گیری آن با استفاده از حسگرهای اینرسیایی نیز وجود داشته باشد.

در ابتدا، طی جلساتی با تیم پزشکی همکار، فرآیند متداول ارزیابی بیماران مبتلا به دیستروفی عضلانی دوشن معرفی شد. در این جلسات علاوه بر مرور روش‌های رایج ارزیابی، تجربیات حاصل از پروژه‌های پیشین نیز مطرح شد. یکی از این تجربیات مربوط به استفاده از حسگرهای الکترومایوگرافی سطحی^{۳۴} برای تحلیل وضعیت بیماران بود. اگرچه این روش اطلاعات ارزشمندی از فعالیت عضلات فراهم می‌کرد، اما پیچیدگی نصب حسگرها، حساسیت زیاد سیگنال‌ها به شرایط ثبت و دشواری استخراج شاخص‌های پایدار موجب شده بود که استفاده از آن برای اهداف

^{۳۴} Surface Electromyography (sEMG)

این پروژه مناسب ارزیابی نشود. این تجربه، استفاده از حسگرهای اینرسیایی را به عنوان گزینه اصلی ثبت حرکت در پژوهش حاضر مطرح کرد.

در ادامه، تعدادی از آزمون‌های متداول ارزیابی عملکرد بیماران از جمله آزمون شش دقیقه راه رفتن (Six-Minute Walk Test) و برخی مقیاس‌های عملکردی دیگر مورد مطالعه قرار گرفتند. هرچند این آزمون‌ها اطلاعات مفیدی درباره وضعیت کلی بیمار ارائه می‌کنند، اما بررسی آن‌ها نشان داد که بسیاری از شاخص‌های حاصل از این آزمون‌ها به صورت مستقیم با داده‌های قابل استخراج از حسگرهای اینرسیایی قابل ارتباط نیستند و یا تنها بخشی از توانایی‌های حرکتی بیمار را ارزیابی می‌کنند.


به منظور شناخت بهتر فرآیند ارزیابی بالینی، در ادامه این پژوهش، جلسات معاینه بیماران در مرکز درمانی مورد مشاهده قرار گرفت. در این جلسات، پزشک متخصص با استفاده از آزمون‌های عملکردی مختلف، توانایی بیماران در انجام فعالیت‌هایی نظیر راه رفتن، برخاستن از صندلی، نشستن، برخاستن از روی زمین، بالا رفتن از پله و سایر حرکات عملکردی را بررسی می‌کرد. همچنین در برخی آزمون‌ها، قدرت عضلانی بیمار از طریق اعمال نیرو توسط پزشک یا درخواست اعمال نیرو از سوی بیمار ارزیابی می‌شد. مشاهده مستقیم این فرآیند نقش مهمی در شناخت معیارهای مورد توجه پزشک هنگام ارزیابی عملکرد بیماران داشت.

پس از مطالعه روش‌های مختلف و بررسی امکان پیاده‌سازی آن‌ها با استفاده از حسگرهای اینرسیایی، مقیاس‌های عملکردی دیگری از جمله Motor Function Measure (MFM) نیز مورد بررسی قرار گرفتند. با این حال، تحلیل ساختار این آزمون‌ها نشان داد که بخش قابل توجهی از آیتم‌های آن‌ها نیازمند ارزیابی‌هایی هستند که تنها از طریق داده‌های حرکتی ثبت‌شده توسط IMU قابل اندازه‌گیری نیستند یا به تجهیزات مکمل نیاز دارند.

در نهایت، با جمع‌بندی مطالعات انجام‌شده، مشاهدات بالینی و بررسی قابلیت اندازه‌گیری حرکات مختلف توسط حسگرهای اینرسیایی، مقیاس North Star Ambulatory Assessment (NSAA) به عنوان معیار مرجع این پژوهش انتخاب شد. این مقیاس علاوه بر برخورداری از اعتبار بالینی در ارزیابی بیماران مبتلا به DMD، شامل مجموعه‌ای از فعالیت‌های عملکردی است که بخش قابل توجهی از آن‌ها قابلیت تحلیل از طریق داده‌های سینماتیکی ثبت‌شده توسط حسگرهای اینرسیایی را دارند.

مطالعات ارزیابی پایایی و روایی این ابزار نشان داده‌اند که NSAA از اعتبار بالایی برای پایش تغییرات عملکردی بیماران دیستروفی عضلانی دوشن برخوردار است، با این حال وابستگی آن به مشاهده مستقیم و قضاوت ارزیاب می‌تواند منجر به تغییرپذیری بین‌ارزیاب شود [۱۶]. این موضوع به‌ویژه در مواردی که تمایز بین اجرای «طبیعی» و اجرای «اصلاح‌شده» ظریف است، اهمیت بیشتری پیدا می‌کند.

از منظر مهندسی تحلیل حرکت، بسیاری از معیارهای کیفی NSAA (مانند استفاده از حرکات جبرانی، تغییر در دامنه حرکتی یا کاهش سرعت اجرای حرکت) می‌توانند با تغییر در پارامترهای سینماتیکی قابل اندازه‌گیری همراه باشند. بنابراین، کمی‌سازی این شاخص‌ها با استفاده از حسگرهای پوشیدنی می‌تواند به توسعه یک چارچوب داده‌محور مکمل برای فرآیند نمره‌دهی کمک نماید. از این رو، NSAA به عنوان مبنای طراحی سامانه پیشنهادی و برچسب‌گذاری داده‌های این پژوهش مورد استفاده قرار گرفت.



شکل ۱: روند تصمیم‌گیری برای انتخاب روش ارزیابی عملکرد

۳.۳ انتخاب مقیاس NSAA به عنوان معیار ارزیابی

پس از بررسی روش‌های مختلف ارزیابی عملکرد حرکتی و مطالعه قابلیت اندازه‌گیری آن‌ها با استفاده از حسگرهای اینرسیایی، لازم بود یک معیار استاندارد به عنوان مرجع نمره‌دهی در این پژوهش انتخاب شود. این معیار علاوه بر اعتبار بالینی، باید شامل فعالیت‌هایی باشد که بتوان آن‌ها را به کمک داده‌های سینماتیکی ثبت‌شده توسط حسگرهای اینرسیایی تحلیل کرد.

در این راستا، مقیاس North Star Ambulatory Assessment (NSAA) به عنوان یکی از معتبرترین ابزارهای ارزیابی عملکرد بیماران سرپایی مبتلا به دیستروفی عضلانی دوشن مورد بررسی قرار گرفت. این مقیاس به طور اختصاصی برای بیماران DMD طراحی شده و امروزه در بسیاری از مراکز درمانی و مطالعات بالینی به عنوان یکی از معیارهای اصلی پایش روند پیشرفت بیماری مورد استفاده قرار می‌گیرد [۶، ۱۶].

NSAA شامل ۱۷ فعالیت عملکردی است که بخش عمده‌ای از توانایی‌های حرکتی بیماران را پوشش می‌دهد. فعالیت‌هایی مانند برخاستن از صندلی، برخاستن از روی زمین، راه رفتن، بالا رفتن از پله، ایستادن روی یک پا، پریدن و دویدن، از جمله آیتم‌های این مقیاس هستند. هر فعالیت بر اساس کیفیت اجرای حرکت در یکی از سه سطح عملکردی امتیازدهی می‌شود که به ترتیب بیانگر ناتوانی در انجام حرکت، انجام حرکت همراه با الگوهای جبرانی و انجام طبیعی حرکت است.

یکی از مهم‌ترین دلایل انتخاب NSAA در این پژوهش، همخوانی قابل توجه بسیاری از آیتم‌های آن با قابلیت‌های حسگرهای اینرسیایی بود. در اغلب این فعالیت‌ها، اطلاعاتی مانند شتاب، سرعت زاویه‌ای، مدت زمان انجام حرکت و الگوی کلی حرکت می‌تواند شاخص‌هایی کمی از کیفیت اجرای فعالیت در اختیار قرار دهند. بنابراین انتظار می‌رود بتوان بخشی از قضاوت بالینی پزشک را با استفاده از تحلیل داده‌های ثبت‌شده توسط حسگرها مدل‌سازی کرد.

بر همین اساس، در پژوهش حاضر NSAA به عنوان معیار مرجع برای برچسب گذاری داده ها و ارزیابی عملکرد مدل های یادگیری ماشین انتخاب شد. در ادامه گزارش، نحوه ثبت داده ها، استخراج ویژگی ها و طراحی مدل های پیش بینی بر مبنای این مقیاس به تفصیل تشریح خواهد شد.

۴.۳ انتخاب حسگرهای اینرسیایی برای ثبت حرکات

پس از انتخاب چارچوب مناسب برای ارزیابی عملکرد بیماران، گام بعدی انتخاب ابزاری بود که بتواند اطلاعات مورد نیاز از حرکات بیماران را ثبت کند. در سال های اخیر فناوری حسگرهای پوشیدنی پیشرفت چشمگیری داشته و ابزارهای متعددی برای اندازه گیری حرکت انسان توسعه یافته اند. در میان این ابزارها، حسگرهای اینرسیایی (Inertial Measurement Unit - IMU) به دلیل ابعاد کوچک، هزینه پایین و امکان استفاده در محیط های خارج از آزمایشگاه، توجه بسیاری از پژوهشگران را به خود جلب کرده اند [۱۷].

در سال های اخیر، استفاده از حسگر اینرسیایی در تحلیل حرکت انسان به طور گسترده ای افزایش یافته است، زیرا این حسگرها نسبت به سیستم های موشن کپچر اپتیکال دارای مزایایی نظیر هزینه کمتر، قابلیت حمل، عدم وابستگی به شرایط نوری و امکان استفاده در محیط های غیرآزمایشگاهی هستند [۱۷]. این ویژگی ها آن ها را به گزینه ای مناسب برای کاربردهای بالینی و پایش بیماران در محیط واقعی تبدیل کرده است.

در سال های اخیر، استفاده از حسگرهای اینرسیایی در تحلیل حرکت بیماران مبتلا به اختلالات عصبی و اسکلتی-عضلانی رشد قابل توجهی داشته است. پژوهش های متعددی از این حسگرها برای ارزیابی بیماران مبتلا به بیماری پارکینسون، سکته مغزی، مولتیپل اسکلروزیس و سایر اختلالات حرکتی استفاده کرده اند. نتایج این مطالعات نشان داده است که داده های حاصل از شتاب سنج وژیروسکوپ می توانند اطلاعات ارزشمندی درباره کیفیت حرکت، تعادل، سرعت انجام فعالیت ها و الگوهای جبرانی بیماران در اختیار قرار دهند [۱۸، ۱۹، ۱۲].

علاوه بر مطالعات بین المللی، پیش از آغاز این پژوهش، در برخی پروژه های انجام شده، از حسگرهای اینرسیایی برای تحلیل حرکت بیماران مبتلا به پارکینسون و سکته مغزی استفاده شده بود. تجربیات حاصل از این مطالعات نشان داد که این حسگرها علاوه بر سادگی استفاده، قابلیت ثبت داده های قابل اعتماد در محیط های درمانی را دارند و می توانند بستر مناسبی برای توسعه سامانه های ارزیابی عملکرد فراهم کنند. این تجربیات یکی از عوامل مؤثر در انتخاب این فناوری برای پژوهش حاضر بود.

یک واحد IMU معمولاً از شتاب سنج وژیروسکوپ سه محوره تشکیل شده است و می تواند شتاب خطی و سرعت زاویه ای اندام های مختلف بدن را اندازه گیری کند. برخلاف سامانه های اپتیکی تحلیل حرکت، استفاده از IMU نیازمند دوربین، فضای آزمایشگاهی یا تجهیزات پیچیده نیست و داده ها را می توان در شرایط واقعی زندگی نیز ثبت کرد [۷].

در این پژوهش نیز هدف طراحی سامانه ای بود که علاوه بر دقت مناسب، قابلیت توسعه و استفاده در محیط های درمانی را داشته باشد. به همین دلیل استفاده از حسگرهای اینرسیایی به عنوان گزینه اصلی ثبت حرکات انتخاب شد. انتخاب این حسگرها علاوه بر کاهش هزینه تجهیزات، امکان ثبت همزمان حرکات چند بخش از بدن را نیز فراهم می کرد و انعطاف پذیری بیشتری در طراحی سامانه اندازه گیری ایجاد نمود.

شایان ذکر است که در این پژوهش، تمرکز اصلی بر انتخاب مناسب محل نصب حسگرها و استخراج اطلاعات حرکتی از داده های ثبت شده بود، نه صرفاً نوع سخت افزار مورد استفاده. از این رو، طراحی سامانه به گونه ای انجام

شد که بتوان با استفاده از تعداد محدودی حسگر، اطلاعات لازم برای تحلیل فعالیت‌های عملکردی بیماران را استخراج کرد. جزئیات طراحی سخت‌افزار، محل نصب حسگرها و نحوه ثبت داده‌ها در فصل دوم گزارش ارائه خواهد شد.

۵.۳ طراحی سامانه پیشنهادی

با توجه به اهداف تعریف‌شده در فصل قبل، سامانه‌ای طراحی شد که بتواند تمامی مراحل مورد نیاز از ثبت داده‌های حرکتی تا پیش‌بینی نمرات عملکردی بیماران را به صورت یکپارچه انجام دهد. این سامانه تنها به بخش اندازه‌گیری محدود نبوده و مجموعه‌ای از زیرسامانه‌های سخت‌افزاری و نرم‌افزاری را در بر می‌گیرد که هر یک وظیفه مشخصی در فرآیند انجام پژوهش بر عهده دارند.

معماری سامانه به گونه‌ای طراحی شد که داده‌های حرکتی ابتدا توسط حسگرهای اینرسیایی نصب‌شده بر روی بدن آزمودنی ثبت شوند. سپس داده‌های ثبت‌شده از طریق ارتباط بی‌سیم به رایانه منتقل شده و توسط نرم‌افزار توسعه‌یافته در محیط MATLAB دریافت، نمایش و ذخیره شوند. پس از پایان فرآیند داده‌برداری، فایل‌های ذخیره‌شده وارد محیط Python شده و مراحل پیش‌پردازش، استخراج ویژگی، کاهش بعد و آموزش مدل‌های یادگیری ماشین بر روی آن‌ها انجام گیرد.

بر این اساس، سامانه پیشنهادی از سه بخش اصلی تشکیل شده است:

۱. سامانه اندازه‌گیری مبتنی بر حسگرهای اینرسیایی؛

۲. سامانه دریافت، نمایش و مدیریت داده‌ها؛

۳. سامانه پردازش داده و پیش‌بینی نمرات عملکردی.


در بخش اندازه‌گیری، پنج گره حسگری پوشیدنی به صورت هم‌زمان اطلاعات شتاب خطی و سرعت زاویه‌ای اندام‌های مختلف بدن را ثبت می‌کنند. این اطلاعات توسط بردهای مبتنی بر ESP32 جمع‌آوری شده و از طریق ارتباط بلوتوث به رایانه منتقل می‌شوند.

در بخش دوم، نرم‌افزاری در محیط MATLAB توسعه داده شد که علاوه بر دریافت هم‌زمان داده‌های پنج حسگر، امکان نمایش برخط سیگنال‌ها، مدیریت آزمون‌ها و ذخیره‌سازی داده‌های هر بیمار را فراهم می‌کند. طراحی این نرم‌افزار به گونه‌ای انجام شد که تمامی اطلاعات خام مورد نیاز برای مراحل بعدی پردازش بدون تغییر ذخیره شوند.

در بخش سوم، داده‌های ذخیره‌شده وارد محیط Python شده و پس از انجام مراحل پاک‌سازی، استخراج ویژگی و کاهش بعد، برای آموزش مدل‌های مختلف یادگیری ماشین مورد استفاده قرار می‌گیرند. خروجی این بخش، مدلی است که قادر است بر اساس ویژگی‌های استخراج‌شده از داده‌های حسگرها، نمره عملکردی بیمار را مطابق با معیار مرجع پیش‌بینی کند.

در طراحی سامانه تلاش شد هر بخش به صورت مستقل قابل توسعه باشد تا در صورت تغییر سخت‌افزار، اضافه شدن حسگرهای جدید یا استفاده از الگوریتم‌های پردازشی دیگر، تنها همان بخش نیاز به اصلاح داشته باشد و سایر اجزای سامانه بدون تغییر قابل استفاده باقی بمانند.

معماری کلی سامانه پیشنهادی در شکل ۲ نمایش داده شده است.



شکل ۲: معماری کلی سامانه پیشنهادی و جریان داده از مرحله ثبت اطلاعات تا پیش‌بینی نمره عملکردی

۶.۳ پیاده‌سازی سامانه داده‌برداری

۱.۶.۳ چیدمان سامانه اندازه‌گیری


اولین گام عملی در اجرای این پژوهش، طراحی سامانه داده‌برداری و تعیین نحوه استقرار حسگرها بر روی بدن آزمودنی بود. هدف از این مرحله، ثبت هم‌زمان حرکات اندام‌های مختلف بدن در هنگام اجرای آزمون‌های عملکردی و ایجاد مجموعه‌داده‌ای مناسب برای مراحل بعدی پردازش و تحلیل بود.

از آنجا که فعالیت‌های انتخاب‌شده در مقیاس NSAA مجموعه‌ای از حرکات اندام فوقانی، اندام تحتانی و تغییرات وضعیت بدن را شامل می‌شوند، لازم بود چیدمان حسگرها به گونه‌ای انتخاب شود که اطلاعات کافی از حرکت بخش‌های مختلف بدن در اختیار قرار گیرد. در عین حال، افزایش تعداد حسگرها موجب پیچیده‌تر شدن فرآیند نصب، افزایش زمان آماده‌سازی بیمار و کاهش راحتی استفاده از سامانه می‌شد. بنابراین، در طراحی سامانه تلاش شد تعادلی میان میزان اطلاعات قابل ثبت و سادگی استفاده برقرار شود.

بر همین اساس، از پنج واحد حسگر پوشیدنی استفاده شد. یک حسگر بر روی پیشانی جهت ثبت حرکات سر، دو حسگر بر روی مچ دست راست و چپ و دو حسگر دیگر بر روی مچ پای راست و چپ نصب شدند. این چیدمان امکان ثبت هم‌زمان حرکات اندام‌های فوقانی و تحتانی را فراهم کرده و اطلاعات مناسبی از الگوی کلی حرکت بیمار در طول اجرای فعالیت‌های مختلف در اختیار قرار می‌دهد.

در این پژوهش از بردهای TTGO T-Wristband به عنوان گره‌های حسگری استفاده شد. هسته پردازشی این بردها تراشه ESP32 Pico-D4 بوده و هر واحد به یک حسگر اینرسیایی مجهز است که قادر به اندازه‌گیری شتاب خطی و سرعت زاویه‌ای در سه محور می‌باشد. استفاده از این بردها علاوه بر ابعاد کوچک و قابلیت نصب آسان، امکان برقراری ارتباط بی‌سیم با رایانه را نیز فراهم می‌کند.

داده‌های هر پنج حسگر به صورت هم‌زمان و از طریق ارتباط بلوتوث به رایانه منتقل شدند. نرخ نمونه‌برداری سامانه در حدود ۹۰ تا ۱۰۰ هرتز تنظیم شد که برای ثبت حرکات عملکردی بیماران و استخراج ویژگی‌های مورد نیاز در مراحل بعدی پژوهش مناسب ارزیابی شد.



شکل ۳: محل نصب پنج حسگر اینرسیایی بر روی بدن آزمودنی

جدول ۱: مشخصات سامانه داده‌برداری

مقدار	مشخصه
۵	تعداد حسگرها
TTGO T-Wrist	نوع برد
ESP32 Pico-D4	پردازنده
Bluetooth	نوع ارتباط
۹۰ تا ۱۰۰ هرتز	نرخ نمونه‌برداری
شتاب خطی و سرعت زاویه‌ای سه‌محوره	سیگنال‌های ثبت‌شده

۲.۶.۳ دلایل انتخاب چیدمان حسگرها

یکی از تصمیم‌های مهم در طراحی سامانه، تعیین تعداد حسگرها و محل نصب آن‌ها بر روی بدن آزمودنی بود. هدف از این مرحله تنها ثبت بیشترین حجم داده ممکن نبود، بلکه دستیابی به چیدمانی بود که ضمن فراهم کردن اطلاعات کافی از الگوی حرکت بیمار، فرآیند نصب و استفاده از سامانه را نیز تا حد امکان ساده نگه دارد. در صورتی که تعداد حسگرها بیش از حد افزایش یابد، علاوه بر افزایش زمان آماده‌سازی بیمار، احتمال جابه‌جایی حسگرها، ایجاد محدودیت در انجام حرکات و کاهش راحتی استفاده از سامانه نیز افزایش خواهد یافت. از سوی دیگر، استفاده از تعداد بسیار کم حسگرها ممکن است باعث از دست رفتن بخشی از اطلاعات حرکتی مورد نیاز شود. به همین دلیل، تلاش شد تعادل مناسبی میان پیچیدگی سامانه و اطلاعات قابل استخراج برقرار شود.

در این پژوهش، یک حسگر بر روی پیشانی نصب شد تا تغییرات وضعیت و حرکات سر در طول انجام آزمون‌ها ثبت شود. حرکات سر در بسیاری از فعالیت‌های عملکردی می‌تواند بیانگر استفاده از الگوهای جبرانی برای حفظ تعادل یا انتقال وزن باشد و در نتیجه اطلاعات مکملی از نحوه اجرای حرکت در اختیار قرار دهد.

دو حسگر دیگر بر روی مچ دست راست و چپ قرار گرفتند. اگرچه بسیاری از فعالیت‌های انتخاب‌شده در مقیاس NSAA بر عملکرد اندام‌های تحتانی تمرکز دارند، اما در بخش قابل توجهی از این فعالیت‌ها، بیماران برای حفظ تعادل یا جبران ضعف عضلانی از اندام‌های فوقانی نیز استفاده می‌کنند. ثبت حرکات دست‌ها امکان بررسی این الگوهای جبرانی را فراهم می‌کند.

همچنین دو حسگر بر روی مچ پای راست و چپ نصب شدند تا اطلاعات مربوط به حرکات اندام‌های تحتانی، شامل تغییرات شتاب و سرعت زاویه‌ای پاها، در طول اجرای آزمون‌ها ثبت شود. از آنجا که اکثر فعالیت‌های عملکردی انتخاب‌شده مبتنی بر راه رفتن، برخاستن، نشست، حفظ تعادل و سایر حرکات وابسته به اندام تحتانی هستند، داده‌های ثبت‌شده توسط این دو حسگر نقش اصلی را در تحلیل عملکرد بیماران ایفا می‌کنند.

در مجموع، چیدمان انتخاب‌شده امکان ثبت هم‌زمان حرکات سر، اندام‌های فوقانی و اندام‌های تحتانی را فراهم کرده و در عین حال، سامانه را به اندازه کافی ساده، سبک و قابل استفاده در محیط‌های درمانی نگه می‌دارد.

۳.۶.۳ نرم‌افزار تعبیه‌شده روی بردهای حسگر

پس از طراحی چیدمان سامانه، لازم بود هر یک از واحدهای حسگری بتوانند داده‌های اندازه‌گیری‌شده را به صورت پیوسته دریافت و برای رایانه ارسال کنند. به همین منظور، برای تمامی بردهای مورد استفاده برنامه‌ای در محیط Arduino توسعه داده شد که وظیفه راه‌اندازی حسگر، نمونه‌برداری از داده‌ها و ارسال آن‌ها از طریق ارتباط بی‌سیم را بر عهده داشت.


هر یک از پنج برد به صورت مستقل اجرا شده و پس از روشن شدن، ابتدا ارتباط با حسگر اینرسیایی را برقرار می‌کرد. پس از انجام مقداردهی اولیه، فرآیند نمونه‌برداری آغاز شده و داده‌های شتاب خطی و سرعت زاویه‌ای در سه محور به صورت پیوسته از حسگر دریافت می‌شدند.

استفاده از ساختار یکسان برای تمامی بردها موجب شد توسعه و نگهداری نرم‌افزار ساده‌تر شده و در صورت نیاز بتوان هر حسگر را بدون اعمال تغییر در سایر بخش‌های سامانه جایگزین کرد.

برای انتقال اطلاعات از ارتباط بلوتوث استفاده شد. هر برد به عنوان یک گره مستقل عمل کرده و داده‌های خود را به صورت جداگانه برای رایانه ارسال می‌کرد. به این ترتیب، نرم‌افزار توسعه‌یافته در محیط MATLAB قادر بود اطلاعات هر پنج حسگر را به طور هم‌زمان دریافت و ذخیره کند.

در طراحی برنامه تلاش شد فرآیند ارسال داده‌ها با حداقل تأخیر انجام شود تا اختلاف زمانی میان داده‌های حسگرهای مختلف تا حد امکان کاهش یابد. همچنین قالب ارسال داده‌ها برای تمامی بردها یکسان در نظر گرفته شد تا فرآیند دریافت و ذخیره‌سازی اطلاعات در نرم‌افزار رایانه ساده‌تر شود.

خروجی هر بسته ارسالی شامل شناسه حسگر، زمان ثبت نمونه و مقادیر شتاب و سرعت زاویه‌ای در سه محور بود. استفاده از قالب یکسان برای تمامی حسگرها موجب شد داده‌های ثبت‌شده در مراحل بعدی پردازش به سادگی با یکدیگر همگام‌سازی و تحلیل شوند.



شکل ۴: فلوچارت عملکرد نرم‌افزار اجراشده روی هر واحد حسگر

۴.۶.۳ نرم‌افزار توسعه‌یافته در محیط MATLAB

پس از طراحی سامانه سخت‌افزاری، نیاز به نرم‌افزاری وجود داشت که بتواند داده‌های ارسال‌شده از حسگرها را به صورت هم‌زمان دریافت، نمایش و ذخیره‌سازی کند. به همین منظور، یک نرم‌افزار اختصاصی در محیط MATLAB توسعه داده شد که به عنوان واسط میان سامانه اندازه‌گیری و مراحل بعدی پردازش داده عمل می‌کند.


در طراحی این نرم‌افزار تلاش شد تمامی نیازهای فرآیند داده‌برداری در یک محیط واحد فراهم شود تا اپراتور بدون نیاز به استفاده از نرم‌افزارهای جانبی بتواند کل فرآیند ثبت اطلاعات را مدیریت کند. به همین دلیل، امکاناتی مانند برقراری ارتباط با حسگرها، مشاهده وضعیت اتصال، نمایش داده‌های دریافتی، مدیریت اطلاعات آزمودنی و ذخیره‌سازی داده‌ها در قالب یک رابط کاربری یکپارچه پیاده‌سازی شد.

در ابتدای هر جلسه داده‌برداری، نرم‌افزار ارتباط بلوتوث با پنج حسگر را برقرار کرده و پس از اطمینان از اتصال صحیح تمامی واحدها، آماده دریافت داده می‌شود. اطلاعات ارسالی از هر حسگر به صورت مستقل دریافت شده و ضمن نمایش برخط، در حافظه نیز ذخیره می‌شوند تا در پایان هر آزمون فایل مربوطه ایجاد شود.

یکی دیگر از قابلیت‌های نرم‌افزار، مدیریت اطلاعات آزمودنی‌ها بود. پیش از شروع ثبت هر آزمون، مشخصات مربوط به بیمار، نوع فعالیت، شماره تکرار آزمون و سایر اطلاعات مورد نیاز توسط اپراتور وارد می‌شد. این اطلاعات همراه با داده‌های حسگر ذخیره شده و از ایجاد ابهام در مراحل بعدی پردازش جلوگیری می‌کرد.

به منظور کاهش احتمال خطا در فرآیند داده‌برداری، رابط کاربری نرم‌افزار به گونه‌ای طراحی شد که وضعیت ارتباط هر حسگر، شروع و پایان ثبت داده و وضعیت ذخیره‌سازی فایل‌ها به صورت واضح برای کاربر قابل مشاهده باشد. همچنین پس از پایان هر آزمون، داده‌های ثبت‌شده به صورت خودکار در مسیر مشخصی ذخیره می‌شدند تا ساختار منظمی از مجموعه داده‌های پروژه ایجاد شود.

با توجه به تعداد زیاد آزمون‌های انجام‌شده در طول پروژه، وجود چنین نرم‌افزاری نقش مهمی در افزایش سرعت داده‌برداری، کاهش خطاهای انسانی و یکپارچگی داده‌های ثبت‌شده ایفا کرد و بستری مناسب برای انجام مراحل بعدی پردازش و تحلیل اطلاعات فراهم ساخت.



شکل ۵: رابط کاربری نرم‌افزار توسعه‌یافته در محیط MATLAB برای دریافت و ذخیره‌سازی هم‌زمان داده‌های حسگرها

۵.۶.۳ فرآیند انجام آزمون‌ها و ثبت داده‌ها

پس از آماده‌سازی سامانه سخت‌افزاری و نرم‌افزار دریافت داده، فرآیند ثبت اطلاعات آزمودنی‌ها مطابق یک روال ثابت انجام می‌شد تا تمامی آزمون‌ها تحت شرایط یکسان ثبت شوند. یکسان بودن شرایط ثبت داده‌ها اهمیت زیادی داشت، زیرا هرگونه تغییر در نحوه نصب حسگرها یا اجرای آزمون‌ها می‌توانست بر کیفیت داده‌های جمع‌آوری‌شده و عملکرد مدل‌های یادگیری ماشین در مراحل بعدی تأثیر بگذارد.

در ابتدای هر جلسه، حسگرهای اینرسیایی مطابق چیدمان معرفی‌شده در بخش قبل بر روی پیشانی، مچ دو دست و مچ دو پا نصب می‌شدند. پس از روشن شدن تمامی بردها، ارتباط بلوتوث میان حسگرها و نرم‌افزار MATLAB برقرار شده و وضعیت اتصال هر پنج حسگر بررسی می‌شد. پس از اطمینان از عملکرد صحیح سامانه، اطلاعات مربوط به آزمودنی و نوع آزمون در نرم‌افزار ثبت می‌شد.

در ادامه، بیمار فعالیت مورد نظر را مطابق دستور پزشک یا درمانگر اجرا می‌کرد. هم‌زمان با اجرای حرکت، داده‌های شتاب و سرعت زاویه‌ای هر پنج حسگر به صورت پیوسته ثبت و در رایانه ذخیره می‌شدند. ثبت اطلاعات از لحظه آغاز فعالیت تا پایان اجرای حرکت ادامه داشت و هیچ‌گونه پردازش یا فیلترگذاری در این مرحله بر روی داده‌های خام انجام نمی‌شد تا تمامی اطلاعات اولیه برای مراحل بعدی حفظ شوند.

پس از پایان هر آزمون، فایل مربوط به آن به صورت مجزا ذخیره شده و فرآیند برای فعالیت بعدی تکرار می‌شد. این روش باعث شد برای هر اجرای مستقل، یک فایل خام شامل اطلاعات تمامی حسگرها در اختیار باشد و در مراحل بعدی بتوان هر فعالیت را به صورت جداگانه مورد بررسی قرار داد.

در طول فرآیند داده‌برداری، تلاش شد تمامی آزمون‌ها تا حد امکان تحت شرایط مشابه انجام شوند. محل نصب حسگرها، نحوه قرارگیری آن‌ها روی بدن و ترتیب اجرای فعالیت‌ها در تمامی جلسات ثابت نگه داشته شد تا تغییرات مشاهده‌شده در داده‌ها تا حد امکان ناشی از عملکرد حرکتی آزمودنی باشد، نه تغییر در شرایط اندازه‌گیری. به منظور کاهش تأثیر عوامل محیطی، تمامی آزمون‌ها توسط تیم درمانی و مطابق دستورالعمل یکسان انجام

شدند و اپراتور در تمامی جلسات از روال ثابتی برای نصب حسگرها و ثبت اطلاعات استفاده کرد.



شکل ۴: مراحل انجام فرآیند داده برداری در پژوهش حاضر

۷.۳ پیش پردازش داده ها

پس از پایان فرآیند داده برداری، فایل های خام ثبت شده مستقیماً برای آموزش مدل های یادگیری ماشین قابل استفاده نبودند. داده های خام علاوه بر آنکه شامل نویزهای ناشی از اندازه گیری بودند، بازه های زمانی قبل و بعد از اجرای هر فعالیت را نیز در بر می گرفتند و ساختار مناسبی برای استخراج ویژگی نداشتند. بنابراین پیش از ورود داده ها به مرحله یادگیری ماشین، مجموعه ای از عملیات پیش پردازش بر روی تمامی فایل ها انجام شد. فرآیند پیش پردازش به گونه ای طراحی شد که تمامی داده ها با روشی یکسان پردازش شوند و امکان تکرار این مراحل برای داده های جدید نیز وجود داشته باشد. این فرآیند شامل فیلترگذاری سیگنال ها، جداسازی بازه زمانی مربوط به هر فعالیت، آماده سازی فایل ها، استخراج ویژگی ها، نرمال سازی داده ها و در صورت نیاز کاهش بعد داده ها بود.

مراحل مختلف این فرآیند در ادامه این فصل به ترتیب اجرای آن ها تشریح شده اند.

۱.۷.۳ دریافت فایل های خام

در پایان هر آزمون، نرم افزار توسعه یافته در محیط MATLAB داده های دریافتی از پنج حسگر را به صورت هم زمان در قالب فایل های جداگانه ذخیره می کرد. هر فایل شامل اطلاعات کامل یک اجرای مستقل از یک فعالیت مشخص بود و تمامی نمونه های ثبت شده از حسگرهای نصب شده روی بدن آزمودنی را در بر می گرفت. از آنجا که هدف اصلی این مرحله حفظ تمامی اطلاعات اندازه گیری شده بود، هیچ گونه پردازش یا تغییر بر روی داده ها هنگام ذخیره سازی انجام نشد و تمامی سیگنال ها به صورت خام ثبت شدند. این موضوع باعث شد در مراحل بعدی امکان اعمال روش های مختلف پردازش سیگنال بدون از دست رفتن اطلاعات اولیه وجود داشته باشد.

پس از پایان جلسات داده‌برداری، تمامی فایل‌های خام به عنوان ورودی مرحله پیش‌پردازش مورد استفاده قرار گرفتند.

۲.۷.۳ فیلترگذاری سیگنال‌ها

سیگنال‌های ثبت‌شده توسط حسگرهای اینرسیایی علاوه بر اطلاعات حرکتی، شامل نویزهای ناشی از اندازه‌گیری، ارتعاشات محیطی و خطاهای لحظه‌ای حسگر نیز بودند. به منظور کاهش تأثیر این عوامل، پیش از هرگونه تحلیل، عملیات فیلترگذاری بر روی تمامی داده‌ها انجام شد.

در این پژوهش از فیلتر پایین‌گذر باترورث مرتبه چهارم استفاده شد. این فیلتر به دلیل پاسخ فرکانسی مناسب و حفظ شکل اصلی سیگنال، یکی از متداول‌ترین روش‌های مورد استفاده در پردازش داده‌های بیومکانیکی محسوب می‌شود.

اعمال این فیلتر موجب حذف بخش عمده نویزهای فرکانس بالا شده و سیگنال‌های نرم‌تر و مناسب‌تری را برای مراحل بعدی پردازش فراهم کرد.

در این پژوهش، برای تمامی سیگنال‌های ثبت‌شده از فیلتر پایین‌گذر Butterworth مرتبه چهارم استفاده شد. اعمال فیلتر پیش از سایر مراحل پردازش باعث شد مؤلفه‌های نویزی حذف شده و سیگنال‌های حاصل، نمایانگر دقیق‌تری از حرکت واقعی آزمودنی باشند. تمامی مراحل فیلترگذاری به صورت خودکار بر روی تمامی فایل‌های ثبت‌شده انجام شدند.

۳.۷.۳ جداسازی فعالیت‌ها

در برخی از آزمون‌ها، داده‌های ثبت‌شده علاوه بر بخش اصلی حرکت، شامل زمان قبل از شروع و پس از پایان فعالیت نیز بودند. وجود این قسمت‌ها می‌توانست موجب استخراج ویژگی‌های نامرتبط و کاهش دقت مدل‌های یادگیری ماشین شود.

به همین دلیل، پس از فیلترگذاری، بازه زمانی مربوط به اجرای واقعی هر فعالیت از سیگنال جدا شد. در فعالیت‌هایی که نیاز به جداسازی داشتند، با استفاده از الگوریتم تشخیص حرکت توسعه‌یافته در محیط MATLAB، ابتدا زمان شروع و پایان فعالیت تعیین و سپس تنها بخش مربوط به اجرای حرکت استخراج شد.

در برخی فعالیت‌ها که کل فایل تنها شامل اجرای همان حرکت بود، نیازی به انجام این مرحله وجود نداشت و داده‌ها مستقیماً وارد مراحل بعدی شدند.

۴.۷.۳ آماده‌سازی داده‌ها برای تحلیل

پس از پایان مراحل فیلترگذاری و جداسازی فعالیت‌ها، داده‌های آماده‌شده برای ورود به محیط Python ذخیره شدند. در این مرحله، تمامی فایل‌ها دارای ساختاری یکنواخت بودند و هر نمونه تنها شامل اطلاعات مربوط به اجرای یک فعالیت مشخص بود.

در ادامه، اسکرپت‌های توسعه‌یافته در محیط Python فایل‌های تولیدشده را خوانده و پس از بررسی کامل بودن داده‌ها، نمونه‌های نامعتبر یا ناقص را حذف کردند. همچنین قالب داده‌ها به گونه‌ای بازآرایی شد که تمامی نمونه‌ها با ساختاری یکسان وارد مرحله استخراج ویژگی شوند.

خروجی این مرحله مجموعه داده‌ای پاک‌سازی شده و استاندارد بود که مبنای استخراج ویژگی‌ها و آموزش مدل‌های یادگیری ماشین در مراحل بعدی پژوهش قرار گرفت.

۸.۳ استخراج ویژگی‌ها

پس از انجام مراحل پیش‌پردازش، سیگنال‌های ثبت شده توسط حسگرهای اینرسیایی برای استفاده مستقیم در الگوریتم‌های یادگیری ماشین مناسب نبودند. از آنجا که این الگوریتم‌ها معمولاً بر روی مجموعه‌ای از ویژگی‌های عددی آموزش داده می‌شوند، لازم بود اطلاعات موجود در سیگنال‌های خام به مجموعه‌ای از شاخص‌های کمی تبدیل شوند که بتوانند خصوصیات اصلی حرکت را توصیف کنند.

به همین منظور، در این پژوهش فرآیند استخراج ویژگی بر روی تمامی سیگنال‌های آماده شده انجام شد. در این مرحله، برای هر محور از شتاب‌سنج وژیروسکوپ هر حسگر، مجموعه‌ای از ویژگی‌های آماری و سیگنالی محاسبه گردید. این ویژگی‌ها به گونه‌ای انتخاب شدند که بتوانند اطلاعاتی درباره شدت حرکت، میزان تغییرات، پراکندگی داده‌ها، تقارن سیگنال و سایر خصوصیات حرکتی را در اختیار مدل‌های یادگیری ماشین قرار دهند. تمامی مراحل استخراج ویژگی به صورت خودکار و با استفاده از اسکریپت‌های توسعه یافته در محیط Python انجام شد و برای تمامی نمونه‌ها فرآیندی یکسان اجرا گردید. خروجی این مرحله، ماتریسی از ویژگی‌ها بود که هر سطر آن متناظر با یک نمونه و هر ستون آن متناظر با یک ویژگی استخراج شده بود.

۱.۸.۳ ویژگی‌های استخراج شده

برای هر یک از سیگنال‌های ثبت شده، مجموعه‌ای از ویژگی‌های حوزه زمان محاسبه شد. انتخاب این ویژگی‌ها بر اساس مطالعات پیشین در زمینه تحلیل حرکت و همچنین قابلیت آن‌ها در توصیف رفتار آماری سیگنال انجام گرفت.

ویژگی‌های استخراج شده شامل شاخص‌هایی نظیر مقدار میانگین، انحراف معیار، واریانس، حداقل و حداکثر مقدار، دامنه تغییرات، میانه، چارک‌های اول و سوم، فاصله بین چارکی، انرژی سیگنال، مقدار $RMS^{۳۵}$ ، چولگی، کشیدگی، ضریب تغییرات، میانگین قدر مطلق، میانگین تغییرات متوالی و سایر ویژگی‌های آماری بودند. از آنجا که هر حسگر شامل شش کانال اندازه‌گیری (سه محور شتاب‌سنج و سه محور ژيروسکوپ) است، تمامی ویژگی‌ها برای هر یک از این کانال‌ها به صورت مستقل محاسبه شدند. در نهایت، ویژگی‌های استخراج شده از تمامی حسگرها با یکدیگر ادغام شده و بردار ویژگی نهایی هر نمونه تشکیل گردید.


^{۳۵} Root Mean Square

جدول ۲: ویژگی‌های استخراج‌شده از هر سیگنال

ویژگی	توضیح
Count	نمونه‌ها تعداد
Mean	میانگین
Standard Deviation	معیار انحراف
Variance	واریانس
Minimum	کمینه
Maximum	بیشینه
Range	تغییرات دامنه
Median	میانه
First Quartile	اول چارک
Third Quartile	سوم چارک
Interquartile Range	چارک‌ها بین فاصله
Mean Absolute Value	مطلق قدر میانگین
Root Mean Square	□□□
Skewness	چولگی
Kurtosis	کشیدگی
Energy	انرژی
Entropy	آنتروپی
Zero Crossing Rate	صفر از عبور نرخ

از آنجا که پنج حسگر مورد استفاده قرار گرفتند و هر حسگر شامل شش سیگنال (سه محور شتاب و سه محور سرعت زاویه‌ای) بود، ویژگی‌های فوق برای تمامی کانال‌ها استخراج شدند. در نتیجه، برای هر آزمون یک بردار ویژگی با ابعاد بالا تولید شد که مبنای مراحل بعدی تحلیل قرار گرفت.

در پایان فرآیند استخراج ویژگی، برای هر نمونه تعداد ۶۹۰ ویژگی عددی تولید شد. این مجموعه ویژگی‌ها به عنوان ورودی مدل‌های یادگیری ماشین مورد استفاده قرار گرفت.



شکل ۷: استخراج ویژگی

۹.۳ کاهش بعد ویژگی‌ها

پس از استخراج ویژگی‌ها، برای هر نمونه یک بردار شامل ۶۹۰ ویژگی در اختیار قرار گرفت. اگرچه استفاده از تعداد زیاد ویژگی‌ها می‌تواند اطلاعات بیشتری از داده‌ها در اختیار مدل قرار دهد، اما افزایش ابعاد داده ممکن است موجب افزایش پیچیدگی محاسبات، ایجاد هم‌بستگی میان ویژگی‌ها و کاهش توان تعمیم مدل شود. به همین دلیل، در این پژوهش تأثیر استفاده از روش کاهش بعد نیز مورد بررسی قرار گرفت.

برای این منظور، از روش تحلیل مؤلفه‌های اصلی^{۳۶} استفاده شد. این روش با تبدیل ویژگی‌های اولیه به مجموعه‌ای از مؤلفه‌های متعامد، بیشترین میزان واریانس داده را در تعداد کمتری از متغیرها حفظ می‌کند. پیش از اعمال PCA، تمامی ویژگی‌ها با استفاده از روش استاندارد سازی^{۳۷} نرمال‌سازی شدند تا میانگین هر ویژگی برابر صفر و انحراف معیار آن برابر یک شود. انجام این مرحله از آن جهت ضروری است که PCA نسبت به مقیاس ویژگی‌ها حساس بوده و وجود اختلاف زیاد میان دامنه مقادیر ویژگی‌ها می‌تواند بر نتایج تحلیل مؤلفه‌های اصلی تأثیر بگذارد.

در این پژوهش دو رویکرد مستقل مورد بررسی قرار گرفت. در رویکرد اول، مدل‌های یادگیری ماشین مستقیماً بر روی ویژگی‌های استخراج‌شده آموزش داده شدند. در رویکرد دوم، PCA به عنوان بخشی از Pipeline تعریف شد و تنها بر روی داده‌های آموزش برازش داده شد و سپس مدل‌های یادگیری ماشین با استفاده از ویژگی‌های کاهش‌یافته آموزش داده شدند. مقایسه نتایج این دو رویکرد امکان بررسی تأثیر کاهش بعد بر عملکرد مدل‌ها را فراهم کرد.

^{۳۶}Principal Component Analysis (PCA)
^{۳۷}Standardization

۱۰.۳ آموزش مدل‌های یادگیری ماشین

پس از استخراج ویژگی‌ها و آماده‌سازی مجموعه داده، مرحله آموزش مدل‌های یادگیری ماشین آغاز شد. هدف از این مرحله، بررسی توانایی الگوریتم‌های مختلف در پیش‌بینی نمره عملکردی بیماران بر اساس ویژگی‌های استخراج‌شده از داده‌های حسگرهای اینرسیایی بود.

به منظور انجام یک مقایسه منصفانه، تمامی مدل‌ها با استفاده از مجموعه ویژگی‌های یکسان آموزش داده شدند و معیارهای ارزیابی نیز برای تمامی آن‌ها به صورت مشابه محاسبه گردید. همچنین، تمامی مراحل پیش‌پردازش مورد نیاز هر مدل، شامل نرمال‌سازی ویژگی‌ها و در صورت استفاده، کاهش بعد با روش PCA، در قالب یک Pipeline یکپارچه پیاده‌سازی شد تا از بروز نشت اطلاعات^{۳۸} بین داده‌های آموزش و آزمون جلوگیری شود. در این پژوهش، دو روش مختلف برای تقسیم داده‌ها و ارزیابی مدل‌ها مورد بررسی قرار گرفت که در ادامه معرفی می‌شوند.

۱.۱۰.۳ تقسیم‌بندی تصادفی با تعداد نمونه ثابت

در نخستین روش ارزیابی، برای هر کلاس تعداد ثابتی از نمونه‌ها به صورت تصادفی برای آموزش و آزمون انتخاب شدند. در هر تکرار، ۲۰ نمونه از هر کلاس برای آموزش و ۵ نمونه برای آزمون مورد استفاده قرار گرفتند. این فرآیند به صورت تصادفی ۱۰۰ بار تکرار شد تا اثر انتخاب تصادفی داده‌ها بر عملکرد مدل‌ها کاهش یابد. در پایان، میانگین معیارهای ارزیابی در تمامی تکرارها به عنوان عملکرد نهایی هر مدل گزارش شد. این روش امکان بررسی پایداری مدل‌ها در برابر تقسیم‌بندی‌های مختلف داده را فراهم می‌کند.

۲.۱.۰.۳ اعتبارسنجی متقاطع

در کنار تقسیم‌بندی تصادفی، از روش اعتبارسنجی متقاطع طبقه‌بندی‌شده نیز برای ارزیابی مدل‌ها استفاده شد. در این روش، داده‌ها با استفاده از الگوریتم Stratified K-Fold به پنج بخش تقسیم شدند؛ به گونه‌ای که نسبت نمونه‌های هر کلاس در تمامی دسته‌ها حفظ شود.

به منظور کاهش وابستگی نتایج به یک تقسیم‌بندی خاص، فرآیند اعتبارسنجی پنج‌تایی پنج مرتبه با چینش‌های تصادفی مختلف تکرار شد. بنابراین عملکرد هر مدل بر اساس نتایج حاصل از ۲۵ مرحله آموزش و آزمون محاسبه گردید.

استفاده از اعتبارسنجی متقاطع باعث می‌شود تمامی نمونه‌های موجود در مجموعه داده حداقل یک بار در مجموعه آزمون قرار گیرند و در نتیجه برآورد دقیق‌تری از توانایی تعمیم مدل به دست آید.

۳.۱.۰.۳ مدل‌های مورد استفاده

به منظور بررسی عملکرد روش‌های مختلف یادگیری ماشین، سه الگوریتم متداول برای مسئله طبقه‌بندی انتخاب شدند. این مدل‌ها شامل ماشین بردار پشتیبان^{۳۹}، نزدیک‌ترین همسایه^{۴۰} و جنگل تصادفی^{۴۱} بودند.

^{۳۸}Data Leakage

^{۳۹}SVM

^{۴۰}KNN

^{۴۱}Random Forest

مدل ماشین بردار پشتیبان با استفاده از هسته شعاعی^{۴۲} پیاده‌سازی شد. این الگوریتم به دلیل توانایی مناسب در مدل‌سازی مرزهای تصمیم‌گیری غیرخطی، یکی از پرکاربردترین روش‌ها در مسائل طبقه‌بندی داده‌های زیستی محسوب می‌شود.

الگوریتم KNN نیز با استفاده از پنج همسایه نزدیک اجرا شد. این روش بر اساس شباهت میان نمونه‌های آموزشی و نمونه جدید تصمیم‌گیری می‌کند و به عنوان یکی از ساده‌ترین روش‌های یادگیری نظارت‌شده شناخته می‌شود.

همچنین، الگوریتم Random Forest با ۵۰۰ درخت تصمیم آموزش داده شد. استفاده از تعداد زیاد درخت‌ها موجب افزایش پایداری مدل و کاهش احتمال بیش‌برازش نسبت به یک درخت تصمیم منفرد می‌شود.

۴.۱۰.۳ Pipeline پردازش داده

به منظور جلوگیری از نشت اطلاعات بین مجموعه آموزش و آزمون، تمامی مراحل پیش‌پردازش در قالب یک Pipeline پیاده‌سازی شدند. در این ساختار، ابتدا ویژگی‌ها با استفاده از روش StandardScaler استانداردسازی شدند. سپس در صورت فعال بودن کاهش بعد، تحلیل مؤلفه‌های اصلی (PCA) تنها بر روی داده‌های آموزش برازش داده شد و همان تبدیل بر روی داده‌های آزمون اعمال گردید. در نهایت، داده‌های پردازش‌شده برای آموزش مدل یادگیری ماشین مورد استفاده قرار گرفتند.

استفاده از Pipeline باعث شد تمامی مراحل پردازش در هر بار آموزش مدل به صورت مستقل انجام شوند و احتمال بروز Data Leakage به طور کامل حذف گردد.

۱۱.۳ معیارهای ارزیابی

به منظور مقایسه عملکرد مدل‌های مختلف، از چندین معیار متداول ارزیابی طبقه‌بندی استفاده شد. این معیارها دید مناسبی از توانایی مدل در تشخیص صحیح کلاس‌ها ارائه می‌کنند.

در این پژوهش، معیارهای Accuracy، Precision، Recall، F1-score و Specificity برای تمامی مدل‌ها محاسبه شدند. همچنین، به منظور بررسی نحوه توزیع خطاهای مدل، ماتریس درهم‌ریختگی (Confusion Matrix) نیز برای هر الگوریتم استخراج شد.

برای مسائل چندکلاسه، مقادیر Precision، Recall و F1-score با استفاده از میانگین Macro محاسبه شدند تا تمامی کلاس‌ها سهم یکسانی در ارزیابی عملکرد مدل داشته باشند. همچنین، مقدار Specificity نیز بر اساس میانگین اختصاصی هر کلاس محاسبه گردید.

۱۲.۳ روند اجرای آزمایش‌ها

پس از آماده‌سازی مجموعه داده و پیاده‌سازی مدل‌های یادگیری ماشین، مجموعه‌ای از آزمایش‌ها برای ارزیابی عملکرد مدل‌ها طراحی و اجرا شد. هدف از این آزمایش‌ها، بررسی تأثیر روش‌های مختلف کاهش بعد و مقایسه عملکرد الگوریتم‌های یادگیری ماشین در پیش‌بینی نمرات عملکردی بیماران بود.

^{۴۲}RBF Kernel

به همین منظور، تمامی آزمایش‌ها در دو حالت مستقل انجام شدند. در حالت اول، مدل‌های یادگیری ماشین مستقیماً با استفاده از ویژگی‌های استخراج‌شده آموزش داده شدند. در حالت دوم، پیش از آموزش مدل‌ها، روش تحلیل مؤلفه‌های اصلی (PCA) بر روی داده‌های آموزش اعمال شد و سپس مدل‌ها با استفاده از ویژگی‌های کاهش‌یافته آموزش دیدند.


برای هر یک از این دو حالت، دو روش مختلف ارزیابی شامل تقسیم‌بندی تصادفی داده‌ها و اعتبارسنجی متقاطع مورد استفاده قرار گرفت. تمامی آزمایش‌ها برای تمامی الگوریتم‌های یادگیری ماشین با تنظیمات یکسان اجرا شدند تا امکان مقایسه منصفانه نتایج فراهم شود.

در پایان هر آزمایش، معیارهای ارزیابی محاسبه و نتایج حاصل برای تحلیل نهایی ذخیره شدند. این نتایج در فصل بعد مورد بررسی و مقایسه قرار خواهند گرفت.

۱.۱۲.۳ مراحل اجرای Pipeline

روند اجرای هر آزمایش مطابق مراحل زیر انجام شد:

۱. بارگذاری داده‌های پیش‌پردازش‌شده؛
۲. تقسیم داده‌ها به مجموعه آموزش و آزمون؛
۳. استانداردسازی ویژگی‌ها با استفاده از StandardScaler؛
۴. اعمال PCA (در صورت فعال بودن) تنها بر روی داده‌های آموزش؛
۵. آموزش مدل یادگیری ماشین؛
۶. پیش‌بینی برچسب نمونه‌های آزمون؛
۷. محاسبه معیارهای ارزیابی و ذخیره نتایج.



شکل ۸: روند اجرای هر آزمایش در Pipeline طراحی‌شده

۱۳.۳ ابزارهای نرم‌افزاری مورد استفاده

در این پژوهش، توسعه بخش‌های مختلف سامانه با استفاده از چند محیط نرم‌افزاری انجام شد. برنامه‌های اجرا شده روی بردهای حسگر با استفاده از محیط Arduino IDE توسعه یافتند. دریافت داده‌ها، مدیریت ارتباط بلوتوث و ذخیره‌سازی اطلاعات در محیط MATLAB انجام شد. همچنین تمامی مراحل پیش‌پردازش، استخراج ویژگی، کاهش بعد و آموزش مدل‌های یادگیری ماشین در محیط Python پیاده‌سازی گردید. در بخش یادگیری ماشین از کتابخانه‌های NumPy، Pandas، Scikit-learn و Matplotlib برای پردازش داده‌ها، آموزش مدل‌ها و تحلیل نتایج استفاده شد.

جمع‌بندی

در این فصل، مراحل طراحی و پیاده‌سازی سامانه پیشنهادی به طور کامل تشریح شد. ابتدا ساختار سامانه داده‌برداری، چیدمان حسگرهای اینرسیایی و نرم‌افزارهای توسعه‌یافته برای ثبت اطلاعات معرفی شدند. سپس فرآیند پیش‌پردازش داده‌ها، استخراج ویژگی، کاهش بعد و آموزش مدل‌های یادگیری ماشین توضیح داده شد. در ادامه، نحوه طراحی آزمایش‌ها، روش‌های ارزیابی مدل‌ها و معیارهای مورد استفاده برای سنجش عملکرد الگوریتم‌ها ارائه گردید. بر اساس این زیرساخت، در فصل بعد نتایج حاصل از اجرای مدل‌های مختلف ارائه شده و عملکرد آن‌ها با یکدیگر مقایسه خواهد شد.

۴ نتایج و بحث

۱.۴ مقدمه


در این فصل، نتایج حاصل از مراحل مختلف پژوهش شامل بررسی داده‌های ثبت‌شده، پیش‌پردازش سیگنال‌ها، استخراج ویژگی، کاهش بعد و آموزش مدل‌های یادگیری ماشین ارائه و تحلیل می‌شود. هدف از این فصل تنها گزارش مقادیر عددی معیارهای ارزیابی نیست، بلکه بررسی رفتار مدل‌ها، تحلیل نقاط قوت و ضعف آن‌ها و ارزیابی تأثیر هر یک از مراحل پردازش بر عملکرد نهایی سامانه است.

ابتدا کیفیت داده‌های ثبت‌شده و نتایج مراحل آماده‌سازی داده بررسی می‌شود. سپس عملکرد مدل‌های مختلف در دو حالت استفاده از ویژگی‌های اولیه و ویژگی‌های کاهش‌یافته توسط روش PCA مقایسه شده و در پایان، مهم‌ترین ویژگی‌های مؤثر در تصمیم‌گیری مدل‌ها تحلیل می‌شوند.

۲.۴ بررسی داده‌های ثبت‌شده


در نخستین مرحله، مجموعه داده ثبت‌شده توسط سامانه پیشنهادی مورد بررسی قرار گرفت تا کیفیت داده‌ها و توزیع نمونه‌های موجود ارزیابی شود. این بررسی علاوه بر ارائه شناخت اولیه از مجموعه داده، مبنایی برای تحلیل نتایج مدل‌های یادگیری ماشین نیز فراهم می‌کند.

شکل ۹ نمونه‌ای از سیگنال‌های ثبت‌شده توسط حسگرهای اینرسیایی را در یکی از فعالیت‌های عملکردی نشان می‌دهد. همان‌گونه که مشاهده می‌شود، تغییرات زمانی شتاب و سرعت زاویه‌ای در حسگرهای مختلف الگوهای متفاوتی دارند که بیانگر مشارکت اندام‌های مختلف در اجرای فعالیت است.



شکل ۹: نمونه سیگنال‌های ثبت‌شده از حسگرها در فعالیت ایستادن


توزیع نمونه‌ها در کلاس‌های مختلف در **شکل ۱۰** نمایش داده شده است. همان‌گونه که مشاهده می‌شود، تمامی کلاس‌ها دارای تعداد یکسانی از نمونه‌ها هستند و برای هر کلاس ۲۵ نمونه در مجموعه داده در نظر گرفته شده است. متوازن بودن مجموعه داده موجب می‌شود عملکرد مدل‌ها تحت تأثیر عدم تعادل کلاس‌ها قرار نگیرد و معیارهایی مانند Accuracy، Precision، Recall و F1 تصویر قابل اعتمادتری از عملکرد واقعی مدل‌ها ارائه دهند.



شکل ۱۰: توزیع تعداد نمونه ها در کلاس های برچسب گذاری شده

۳.۴ نتایج پیش پردازش داده ها

پس از بررسی اولیه مجموعه داده، مراحل پیش پردازش شامل فیلترگذاری، حذف نویز و آماده سازی داده ها انجام شد. هدف از این مرحله افزایش کیفیت سیگنال ها و آماده سازی آن ها برای استخراج ویژگی بود. یکی از بررسی های انجام شده پس از استخراج ویژگی ها، تحلیل میزان همبستگی بین ویژگی ها بود. همان طور که در **شکل ۱۱** مشاهده می شود، تعدادی از ویژگی ها دارای همبستگی نسبتاً بالایی هستند که وجود اطلاعات تکراری در فضای ویژگی را نشان می دهد. این موضوع استفاده از روش های کاهش بعد مانند PCA را توجیه می کند.



شکل ۱۱: نقشه همبستگی ۲۰ ویژگی با بیشترین واریانس


۴.۴ نتایج استخراج ویژگی

پس از اعمال مراحل پیش‌پردازش، مجموعه‌ای از ویژگی‌های آماری، زمانی و فرکانسی از سیگنال‌های ثبت‌شده استخراج شد. این ویژگی‌ها اطلاعات مختلفی از رفتار دینامیکی حرکت آزمودنی را توصیف می‌کنند و به عنوان ورودی مدل‌های یادگیری ماشین مورد استفاده قرار گرفتند.

با توجه به اینکه تعداد ویژگی‌های استخراج‌شده نسبتاً زیاد بود، پیش از آموزش مدل‌ها ساختار فضای ویژگی مورد بررسی قرار گرفت. نتایج نشان داد بخشی از ویژگی‌ها دارای همبستگی قابل توجهی با یکدیگر هستند که نشان‌دهنده وجود اطلاعات تکراری در داده‌ها است. این موضوع یکی از دلایل اصلی بررسی روش کاهش بعد با استفاده از PCA در ادامه پژوهش محسوب می‌شود.

۵.۴ نتایج مدل‌های یادگیری ماشین


سه مدل مختلف شامل KNN، SVM و Random Forest برای پیش‌بینی کلاس فعالیت آموزش داده شدند. عملکرد این مدل‌ها با استفاده از معیارهای Accuracy، Precision، Recall و F1 مورد ارزیابی قرار گرفت.



شکل ۱۲: مقایسه معیارهای عملکرد مدل ها در دو حالت بدون PCA و با PCA95

مطابق شکل ۱۲، عملکرد مدل های مختلف در دو حالت استفاده از ویژگی های اولیه و ویژگی های کاهش یافته مقایسه شده است. این نمودار امکان بررسی اثر کاهش بعد بر هر یک از الگوریتم ها را فراهم می کند و نشان می دهد که واکنش مدل های مختلف نسبت به اعمال PCA یکسان نیست. علاوه بر معیارهای عددی، برای بررسی دقیق تر نوع خطاهای مدل ها از ماتریس درهم ریختگی نرمال شده استفاده شد. این ماتریس ها نشان می دهند که هر مدل در تشخیص کدام کلاس ها عملکرد مناسب تری داشته و بیشترین اشتباهات بین کدام کلاس ها رخ داده است.


Normalized Confusion Matrices (no_pca)



شکل ۱۳: ماتریس درهم ریختگی نرمال شده مدل ها در حالت no pca


توضیح شکل: این شکل خطاهای بین کلاسی را مشخص می کند و نشان می دهد هر مدل کدام کلاس ها را بهتر یا ضعیف تر تشخیص می دهد.

Normalized Confusion Matrices (pca95)



شکل ۱۴: ماتریس درهم ریختگی نرمال شده مدل ها در حالت pca95

توضیح شکل: این شکل خطاهای بین کلاسی را مشخص می کند و نشان می دهد هر مدل کدام کلاس ها را بهتر یا ضعیف تر تشخیص می دهد.



شکل ۱۵: رتبه بندی مدل ها بر اساس F1 در حالت بدون PCA


توضیح شکل: این شکل جمع بندی سریع از برتری نسبی مدل ها ارائه می دهد و انتخاب مدل نهایی را پشتیبانی می کند.

جدول ۳: مقایسه عملکرد مدل‌های مختلف

مدل	Accuracy	Precision	Recall	F1-score
KNN				
SVM				
Random Forest				


۶.۴ تأثیر کاهش بعد با استفاده از PCA

به منظور بررسی اثر کاهش بعد بر عملکرد مدل‌ها، روش PCA با حفظ ۹۵ درصد واریانس داده‌ها مورد استفاده قرار گرفت. در این بخش نتایج حاصل از آموزش مدل‌ها قبل و بعد از اعمال PCA مقایسه می‌شوند. در این پژوهش، تعداد مؤلفه‌های اصلی به گونه‌ای انتخاب شد که ۹۵ درصد از واریانس کل داده‌ها حفظ شود. به این ترتیب، بخش عمده اطلاعات موجود در داده‌ها بدون حفظ تمامی ویژگی‌های اولیه نگهداری شد.




شکل ۱۶: درصد واریانس توضیح داده شده و تجمعی مؤلفه‌های اصلی

مطابق شکل ۱۶ مشاهده می‌شود که با تعداد محدودی از مؤلفه‌های اصلی می‌توان بخش عمده واریانس داده‌ها را حفظ کرد. این موضوع بیانگر وجود همبستگی میان ویژگی‌های استخراج شده و امکان کاهش بعد بدون از دست رفتن بخش زیادی از اطلاعات است.



شکل ۱۷: پراکندگی نمونه ها در فضای PC1 و PC2

توضیح شکل: این نمودار میزان جداسازی کلاس ها را در فضای $\mathbb{R}^2$ نمایش می دهد و شهودی از دشواری طبقه بندی ارائه می کند.



شکل ۱۸: تغییر F1 هر مدل پس از اعمال PCA95


توضیح شکل: این شکل مشخص می کند کاهش بعد برای هر مدل سودمند بوده یا باعث افت عملکرد شده

است.

۷.۴ تحلیل ویژگی‌های مؤثر


اگرچه مدل‌های یادگیری ماشین قادر به انجام پیش‌بینی با دقت مناسب هستند، اما بررسی ویژگی‌های مؤثر در تصمیم‌گیری مدل می‌تواند در تفسیر نتایج نیز مفید باشد. به همین منظور اهمیت ویژگی‌ها در مدل Random Forest مورد بررسی قرار گرفت.

به منظور افزایش قابلیت تفسیر نتایج، علاوه بر ارزیابی عملکرد مدل‌ها، اهمیت نسبی ویژگی‌های استخراج‌شده نیز بررسی شد. این تحلیل مشخص می‌کند که تصمیم‌گیری مدل تا چه اندازه به هر یک از ویژگی‌های سینماتیکی وابسته بوده است.




شکل ۱۹: ۲۰ ویژگی برتر بر اساس اهمیت در مدل Random Forest

توضیح شکل: این شکل نشان می‌دهد کدام ویژگی‌ها نقش بیشتری در تصمیم‌گیری مدل داشته‌اند و برای تفسیر بالینی/مهندسی مفید است.




شکل ۲۰: مقایسه Recall هر کلاس بین مدل ها no_pca

توضیح شکل: این نمودار حساسیت هر مدل نسبت به هر کلاس را نشان می دهد و برای تحلیل خطاهای کلاس محور استفاده می شود.



شکل ۲۱: مقایسه Recall هر کلاس بین مدل ها pca95

توضیح شکل: این نمودار حساسیت هر مدل نسبت به هر کلاس را نشان می دهد و برای تحلیل خطاهای کلاس محور استفاده می شود.



شکل ۲۲: میانگین نرمال شده ویژگی های برتر برای هر کلاس

توضیح شکل: این نقشه حرارتی الگوی میانگین ویژگی ها در کلاس های مختلف را نشان می دهد و قابلیت تفکیک ویژگی ها را تفسیرپذیر می کند.

۸.۴ جمع بندی فصل

نتایج این فصل نشان داد که سامانه پیشنهادی قادر به ثبت داده های حرکتی با کیفیت مناسب و استخراج ویژگی های مؤثر از سیگنال های حسگرهای اینرسیایی است. بررسی عملکرد مدل های مختلف یادگیری ماشین نیز نشان داد که ویژگی های استخراج شده توانایی مناسبی در تفکیک کلاس های مختلف فعالیت دارند. همچنین مشخص شد که استفاده از روش کاهش بعد PCA بسته به نوع الگوریتم می تواند موجب بهبود یا افت عملکرد شود؛ بنابراین انتخاب استفاده از PCA باید متناسب با مدل مورد استفاده انجام گیرد. علاوه بر این، تحلیل اهمیت ویژگی ها نشان داد که تنها بخشی از ویژگی های استخراج شده نقش اصلی را در فرآیند تصمیم گیری مدل ها ایفا می کنند که این موضوع می تواند در طراحی سامانه های ساده تر و کارآمدتر در آینده مورد استفاده قرار گیرد.

در مجموع، نتایج به دست آمده نشان می دهد که ترکیب حسگرهای اینرسیایی پوشیدنی با روش های پردازش سیگنال و الگوریتم های یادگیری ماشین، رویکردی مناسب برای تحلیل فعالیت های عملکردی و پیش بینی وضعیت حرکتی بیماران مبتلا به دیستروفی عضلانی دوشن فراهم می کند.

۵ جمع بندی

- [1] K. et al. Bushby. "Diagnosis and management of Duchenne muscular dystrophy". In: *The Lancet Neurology* (2010).
- [2] David A. Winter. *Biomechanics and Motor Control of Human Movement*. 4th ed. John Wiley & Sons, 2009.
- [3] Alan EH Emery. "The muscular dystrophies". In: *The Lancet* (2002).
- [4] Eric P. Hoffman, Robert H. Brown, and Louis M. Kunkel. "Dystrophin: the protein product of the Duchenne muscular dystrophy locus". In: *Cell* (1987).
- [5] M. et al. Eagle. "Survival in Duchenne muscular dystrophy". In: *Neuromuscular Disorders* (2002).
- [6] E. et al. Scott. "North Star Ambulatory Assessment for Duchenne muscular dystrophy". In: *Neuromuscular Disorders* (2009).
- [7] A.M. Sabatini. "Estimating three-dimensional orientation of human body parts by inertial/magnetic sensing". In: *Sensors* (2011).
- [8] S.O.H. Madgwick. "An efficient orientation filter for inertial and inertial/magnetic sensor arrays". In: (2011).
- [9] Andreas Bulling, Ulf Blanke, and Bernt Schiele. "A Tutorial on Human Activity Recognition Using Body-Worn Inertial Sensors". In: *ACM Computing Surveys* 46.3 (2014), p. 33.
- [10] Ian T. Jolliffe. *Principal Component Analysis*. Springer, 2002.
- [11] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [12] Oscar D. Lara and Miguel A. Labrador. "A Survey on Human Activity Recognition using Wearable Sensors". In: *IEEE Communications Surveys & Tutorials* 15.3 (2013), pp. 1192–1209.
- [13] Corinna Cortes and Vladimir Vapnik. "Support-vector networks". In: *Machine Learning* 20.3 (1995), pp. 273–297.
- [14] Thomas Cover and Peter Hart. "Nearest Neighbor Pattern Classification". In: *IEEE Transactions on Information Theory* 13.1 (1967), pp. 21–27.
- [15] Leo Breiman. "Random Forests". In: *Machine Learning* 45.1 (2001), pp. 5–32.
- [16] A. et al. Mayhew. "Reliability of the NSAA in Duchenne muscular dystrophy". In: *PLoS One* (2013).

- [17] A. et al. Muro-de-la-Herran. “Gait analysis methods: An overview of wearable and non-wearable systems”. In: *Sensors* (2014).
- [18] Shyamal Patel et al. “A review of wearable sensors and systems with application in rehabilitation”. In: *Journal of NeuroEngineering and Rehabilitation* 9.21 (2012).
- [19] Paolo Bonato. “Wearable Sensors and Systems”. In: *IEEE Engineering in Medicine and Biology Magazine* 29.3 (2010), pp. 25–36.

Abstract

Duchenne Muscular Dystrophy (DMD) is one of the most prevalent and severe genetic neuromuscular disorders in children, characterized by progressive skeletal muscle degeneration and gradual loss of motor function. Quantitative and reliable assessment of motor performance in patients with DMD plays a crucial role in monitoring disease progression, evaluating treatment effectiveness, and designing rehabilitation programs. One of the most widely used clinical tools for functional evaluation is the North Star Ambulatory Assessment (NSAA), a 17-item rating scale in which each task is scored from 0 to 2 based on clinical observation. Despite its clinical value, the qualitative nature of NSAA and its reliance on subjective judgment may introduce inter-rater variability and limit repeatability.

The objective of this study is to design and develop an inertial sensor-based system for quantitative evaluation of motor function indices in patients with DMD, aiming to provide a data-driven complementary framework for clinical scoring. In this approach, multiple inertial measurement units (IMUs), consisting of accelerometers and gyroscopes, were attached to key body segments to record linear acceleration and angular velocity during selected NSAA activities. The raw sensor data were transmitted to the MATLAB environment, where signal preprocessing—including noise reduction, digital filtering, and temporal normalization—was performed. Subsequently, relevant time-domain and frequency-domain features were extracted to construct a structured dataset for further analysis.

Machine learning algorithms were employed to estimate the score of each motor task based on the extracted features, and the predicted scores were compared with clinical evaluations. In the preliminary phase of the study, approximately 12 patients with DMD were clinically observed in collaboration with the medical team, providing valuable insight into motor behavior patterns and practical system constraints. The findings indicate that the proposed inertial sensor-based and data-driven framework can serve as a complementary tool to conventional clinical assessment by enhancing objectivity, accuracy, and repeatability in motor performance evaluation.

The proposed system has the potential to support longitudinal patient monitoring, remote assessment applications, and improved clinical decision-making in future developments.

Keywords: Duchenne Muscular Dystrophy, Inertial Sensors, Motion Analysis, Machine Learning, NSAA, Motor Function Assessment